

Spec-Driven Artificial Intelligence dla badań empirycznych: przegląd zakresowy i architektura kontroli epistemicznej

Grzegorz Wojarnik

lipiec 2026

Uniwersytet Szczeciński, Instytut Ekonomii i Finansów, Szczecin, Polska

ORCID: 0000-0001-6946-547X · e-mail: grzegorz.wojarnik@usz.edu.pl

Streszczenie

Systemy badawcze wspierane przez sztuczną inteligencję coraz częściej automatyzują przeszukiwanie literatury, kodowanie, analizę statystyczną, wizualizację i redagowanie manuskryptów. Sama automatyzacja nie rozwiązuje jednak podstawowego problemu metodologicznego badań empirycznych: jak odróżnić eksplorację od confirmacji, zachować proveniencję, kontrolować swobodę decyzji analitycznych i zapewnić, by twierdzenia nie wykraczały poza status dowodowy danych i projektu badania. Artykuł jest przeglądem zakresowym sześciu podejść istotnych dla tego wyzwania - preregistracji i registered reports, pre-analysis plans w ekonomii, analizy wielowariantowej i specification curve, badań reprodukowalnych i research compendia, standardów FAIR i proveniencji oraz powstających workflow AI-for-science. Podejścia te syntetyzujemy w metodykę spec-driven AI dla badań empirycznych (FSAIM), której skrótowy anons przedstawiono osobno jako notę pozycyjną [10.2139/ssrn.6853581], w której hipotezy, dane, kod, artefakty, twierdzenia i działania AI są traktowane jako audytowalne obiekty w etapowym workflow z bramami zatwierdzania przez człowieka. Proponowana rama przedstawia AI nie jako skrót do pisania, lecz jako element epistemicznie ograniczonego silnika badawczego. Omawiamy implikacje dla ekonomii i finansów empirycznych, gdzie dane wtórne, look-ahead bias, wielość specyfikacji i bodźce publikacyjne tworzą trwałe ryzyka dla wiarygodności.

1. Wprowadzenie

Sztuczna inteligencja przyspiesza dziś każdy etap badania empirycznego: znajduje literaturę, pisze kod, prowadzi analizę, generuje wykresy i redaguje tekst. To przyspieszenie ma jednak cichą cenę. Automatyzacja nie usuwa fundamentalnej podatności badań empirycznych - elastyczności analitycznej, przez którą pokazanie wyłącznie tej kombinacji decyzji, która „wyszła”, daje wynik solidny z pozoru, a w dużej mierze przypadkowy. Co więcej, AI dokłada do tego ryzyka nowe, pod które dotychczasowe zabezpieczenia nie były projektowane: zmyślane cytowania i wyniki, ukryte decyzje zaszyte w promptach, dryf modelu między wersjami API oraz pozorny audyt, w którym drugi model „potwierdza” wynik pierwszego, dzieląc z nim te same błędy. Badanie prowadzone z AI może więc być jednocześnie szybsze i mniej wiarygodne, jeśli udział AI pozostaje nieudokumentowany.

Nauka nie jest wobec tego bezbronna - wypracowała szereg zabezpieczeń: preregistrację i pre-analysis plans, analizę wielowariantową, reprodukowalność kodu i danych, standardy FAIR i proveniencji, polityki data/code czasopism. Każde z nich chroni jednak tylko jeden fragment procesu, a rozwijały się osobno, w różnych dyscyplinach, które rzadko czytają się nawzajem. Nie

istnieje spójna rama wiążąca je w jeden przebieg, a żadne z nich nie obejmuje rozliczalności AI, bo powstały przed erą asystentów generatywnych. Tę lukę artykuł adresuje.

Wkład jest dwojaki. Po pierwsze - mapa: przegląd zakresowy rozproszonej literatury kontroli wiarygodności, uporządkowanej w sześć podejść (warstwy L1-L6). Po drugie - rama: synteza tych podejść w spec-driven development (SDD) rozumiany jako architektura kontroli epistemicznej. Teza główna brzmi wprost: SDD najlepiej rozumieć nie jako narzędzie do pisania czy kodowania z AI, lecz jako sposób pracy, który zamraza intencje, dane, kod, wyniki i udział AI jako audytowalne obiekty ułożone w etapy z bramami zatwierdzania przez człowieka. SDD jest w tym ujęciu kompilatorem dobrych praktyk - składa rozproszone podejścia w jeden wykonywalny workflow i dokłada brakujący we wszystkich element: rozliczalność AI. Odpowiedzi na te pytania robią różnicę dla trzech grup odbiorców - badaczy empirycznych w ekonomii i finansach, redaktorów ustalających polityki data/code oraz twórców narzędzi AI-for-science - a dla każdej z nich rama wskazuje inny, konkretny punkt wejścia. Sama rama ma przy tym status provisional: sprawdzono ją na jednej instancji, jaką było powstawanie tego tekstu, nie zwalidowano zaś empirycznie wobec alternatyw, a pełną listę ograniczeń zawiera rozdział 8.

Artykuł prowadzi przez pięć pytań badawczych. Rozdział 2 uzasadnia potrzebę kontroli na poziomie workflow, ze szczególnym uwzględnieniem ekonomii i finansów. Rozdział 3 opisuje metodę przeglądu. Rozdział 4 mapuje sześć podejść (RQ1: które podejścia rozwiązują które fragmenty problemu). Rozdział 5 syntetyzuje je, wskazując wspólny mechanizm (RQ2) i to, czego razem nie obejmują (RQ3). Rozdział 6 przedstawia ramę SDD i konieczne w świecie AI zabezpieczenia (RQ4). Rozdział 7 przenosi ramę do ekonomii i finansów (RQ5). Rozdział 8 omawia ryzyka i pytania otwarte, a rozdział 9 domyka argument i wskazuje kierunek walidacji. Zgodnie z tezą żadne twierdzenie wstępu nie wyprzedza tego, co pokazują dalsze rozdziały - wstęp jest obietnicą, którą reszta artykułu spłaca.

2. Tło: dlaczego badania empiryczne potrzebują kontroli na poziomie workflow

Między pytaniem badawczym a opublikowanym wynikiem badacz podejmuje setki drobnych decyzji: które obserwacje wykluczyć, jak zdefiniować zmienne, którą specyfikację modelu przyjąć, kiedy zatrzymać zbieranie danych. Każda z osobna bywa uzasadniona; problem powstaje, gdy wybiera się je po zobaczeniu wyników, a raportuje tylko tę kombinację, która potwierdza oczekiwanie. Cztery pojęcia opisują ten mechanizm z różnych stron, a wszystkie mają kotwice w korpusie tego przeglądu. Kerr (1998) nazwał praktyką HARKing formułowanie hipotezy po poznaniu wyniku i przedstawianie jej jako przewidzianej z góry, co odwraca logikę testu - hipoteza dopasowana do danych zawsze wygląda na potwierdzoną [10.1207/s15327957pspr0203_4]. Simmons, Nelson i Simonsohn (2011) pokazali eksperymentalnie, że nieujawniona swoboda decyzji analitycznych pozwala przedstawić niemal dowolny efekt jako istotny statystycznie, i nadali jej nazwę „researcher degrees of freedom” [10.1177/0956797611417632]. Nawet bez świadomego oszustwa sama wielość równie uzasadnionych ścieżek analizy zawyża odsetek fałszywych odkryć: Steegen, Tuerlinckx, Gelman i Vanpaemel (2016) odpowiedzieli na to analizą wielowariantową, która pokazuje wynik dla wszystkich rozsądnych kombinacji decyzji zamiast jednej wybranej [10.1177/1745691616658637], a Simonsohn, Simmons i Nelson (2020) sformalizowali to jako specification curve [10.1038/s41562-020-0912-z]. Skalę problemu ujął Ioannidis (2005), argumentując, że przy typowej mocy testów i presji na wynik dodatni większość opublikowanych ustaleń może być fałszywa [10.1371/journal.pmed.0020124], co Open Science

Collaboration (2015) potwierdziła empirycznie, nie odtwarzając dużej części efektów w masowej próbie replikacji [10.1126/science.aac4716].

Wspólnym mianownikiem tych zjawisk nie jest zła wola, lecz brak zamrożenia decyzji w czasie. Dopóki plan analizy powstaje razem z wynikiem, żadne pojedyncze zabezpieczenie po fakcie nie odróżni odkrycia od artefaktu - i to jest właśnie racja bytu kontroli na poziomie workflow, wiążącej decyzje z momentem ich podjęcia.

W ekonomii i finansach elastyczność analityczna zyskuje dodatkowy wymiar, bo dane są najczęściej wtórne - rynkowe, makroekonomiczne, panelowe od dostawców. Badacz nie zbiera ich sam, lecz przetwarza, więc swoboda przenosi się z projektu eksperymentu na obróbkę danych. White (2000) pokazał formalnie, jak przeszukiwanie wielu strategii na tych samych szeregach czasowych generuje pozornie istotne wyniki - problem szczególnie dotkliwy w finansach, gdzie testuje się tysiące reguł inwestycyjnych [10.1111/1468-0262.00152]. Christensen i Miguel (2018) udokumentowali skalę tego problemu w ekonomii empirycznej i rozproszenie odpowiedzi na niego [10.1257/jel.20171350], a Vilhuber (2020) opisał stan reprodukowalności w ekonomii oraz rolę polityk data/code czasopism [10.1162/99608f92.4f6b9e67]; oba potwierdzają, że dyscyplina ma dojrzałą świadomość problemu, lecz zabezpieczenia pozostają rozproszone. Dane finansowe i makro niosą przy tym własne stopnie swobody, których nie ma w badaniu eksperymentalnym - look-ahead bias, survivorship bias, rewizje szeregów makro, rozbieżne definicje dostawców, wybór okna próby i wielość specyfikacji. Tabela 1 zestawia sześć takich typów, przypisując każdemu odpowiadające mu zamrożenie w ramie SDD; każdy z nich to cicha decyzja o danych wejściowych, którą standardowe polityki data/code - sprawdzające odtwarzalność, nie prespecyfikację - przepuszczają, a którą rama adresuje w etapie data freeze (rozwińcie w rozdz.

Tabela 1. Typy stopni swobody badacza w danych finansowych i ich zamrożenia w SDD.

Typ RDF	Opis	Zamrożenie w SDD
Look-ahead bias (uprzedzanie informacji)	Użycie informacji niedostępnej w momencie decyzji (dane skorygowane wstecz, wskaźniki opublikowane później)	snapshot point-in-time
Survivorship bias (przetrwanie próby)	Próba zawężona do podmiotów, które przetrwały (bazy usuwają wygasłe fundusze/spółki)	deklaracja uniwersum + podmioty wypadłe
Rewizje danych	Szeregi makro (PKB, zatrudnienie) rewidowane po publikacji - dane „ostateczne” ≠ „real-time”	wersja vintage (real-time DB)
Definicje dostawcy	Ten sam wskaźnik różni się między dostawcami (Bloomberg/Refinitiv/CRSP) i wersjami	dostawca + wersja + data ekstrakcji
Market timing / okno próby	Wybór okresu próby (start/koniec, wykluczenie kryzysów) zmienia wynik	prespecyfikacja okna w PAP
Wielość specyfikacji	Wybór modelu, zmiennych kontrolnych, częstotliwości spośród wielu równie uzasadnionych	specification curve / deklaracja rodziny

Źródło: opracowanie własne. 7).

3. Metoda przeglądu

Rama pojęciowa przedstawiona w poprzednim rozdziale - sześć podejść kontroli wiarygodności oraz zarys warstw, które mają je porządkować - nie powstała z intuicji, lecz z systematycznego przeglądu literatury. Niniejszy rozdział opisuje, jak ten przegląd przeprowadzono: jaki typ przeglądu wybrano, z jakich baz korzystano, jak wyszukiwano, przesiewano i kodowano prace oraz jakie ograniczenia metody należy mieć na uwadze przy interpretacji dalszych wyników.

3.1. Typ przeglądu i pytania badawcze

Zastosowano metodę przeglądu zakresowego (scoping review) zgodną z ramą PRISMA-ScR (Preferred Reporting Items for Systematic reviews and Meta-Analyses extension for Scoping Reviews). Wybór tej metody, a nie klasycznego przeglądu systematycznego, wynika z charakteru pytań badawczych: celem nie jest synteza efektu ilościowego, lecz zmapowanie i porównanie rozproszonych podejść kontroli wiarygodności badań oraz zidentyfikowanie luk, które proponowana rama ma wypełnić. Przegląd zakresowy jest właściwą metodą wtedy, gdy celem jest zmapowanie heterogenicznego, rozproszonego po dyscyplinach pola i zidentyfikowanie luk, a nie oszacowanie zbiorczego efektu, które wymagałoby wspólnej miary wyniku. Przegląd odpowiada na pięć pytań badawczych (RQ1-RQ5) zamrożonych w wersji 1.0 zakresu, których pełne brzmienie zawiera Załącznik A.

Przeglądu tego świadomie nie prowadzono jako metaanalizy ani przeglądu systematycznego nastawionego na ocenę siły dowodu, ponieważ metaanaliza wymaga zbioru badań mierzących ten sam, porównywalny efekt za pomocą wspólnej miary wyniku (effect size), którą można agregować w statystykę zbiorczą - a korpus tego przeglądu jest z założenia heterogeniczny. Obejmuje on sześć odrębnych podejść kontroli wiarygodności - od preregistracji, przez analizy wielowariantowe i reprodukowalność, po standardy proveniencji, polityki data/code i rozliczalność agentów AI - których nie łączy żadna wspólna miara efektu, a same prace nie testują wspólnej hipotezy, lecz opisują różne mechanizmy zabezpieczające różne fragmenty procesu badawczego. Agregacja ilościowa byłaby tu nie tyle niepożądana, co pozbawiona przedmiotu: nie istnieje wielkość, którą można by uśrednić między preregistracją a formatem RO-Crate. Właściwym gatunkiem jest zatem przegląd zakresowy z syntezą pojęciową (conceptual/framework synthesis), którego produktem jest mapa podejść i rama porządkująca - warstwy L1-L6 oraz proponowana rama SDD - a nie zbiorczy estymator efektu. Ta sama dyscyplina twierdzeń, którą artykuł postuluje wobec badań empirycznych, nakazuje nie przedstawiać syntezy narracyjnej w statystycznym kostiumie metaanalizy.

3.2. Bazy źródłowe i ich substytucja

Ze względu na środowisko obliczeniowe przeglądu - agent badawczy działający w piaskownicy sieciowej - trzy główne bazy komercyjne, Scopus (Elsevier), Web of Science (Clarivate) oraz EconLit (EBSCO), były niedostępne. Zamiast nich jako podstawę wyszukiwania przyjęto OpenAlex, otwarty indeks obejmujący ponad 250 milionów prac i w praktyce stanowiący nadzbiór pokrycia Scopus i Web of Science, uzupełniony o arXiv (preprinty) i Crossref (metadane wydawnicze). Za niedostępną uznano również bazę PubMed/PMC, jednak jej zawartość biomedyczna dociera do korpusu pośrednio przez OpenAlex. Ta substytucja jest świadomym ograniczeniem metody, opisanym szerzej w sekcji 3.7 oraz udokumentowanym w Załączniku B (log wyszukiwania); pełne teksty prac zamkniętych, głównie wydawnictwa Elsevier, pozyskiwano ręcznym kanałem autorskim.

3.3. Strategia wyszukiwania


Wyszukiwanie prowadzono w dwóch komplementarnych trybach. Tryb pierwszy, oparty na zapytaniach tematycznych, obejmował siedem rodzin fraz odpowiadających sześciu podejściom kontroli (warstwy L1-L6) plus wątek „stopni swobody badacza” w ekonomii, każde z filtrem od roku 1998 wzwyż i bez górnej granicy. Tryb drugi, czyli import celowany kotwic, wprowadził czternaście prac-źródeł - jedenaście DOI i trzy identyfikatory arXiv - reprezentujących kanoniczne pozycje każdego podejścia, a następnie rozszerzył je o graf cytowań, obejmujący zarówno odwołania wstecz, jak i cytowania w przód. Import kotwic celowo omija dolny filtr roku, dzięki czemu prace fundamentalne sprzed 1998, z których najstarsza pochodzi z 1955, wchodzą do korpusu poprzez powiązania cytowań. Pełne łańcuchy zapytań wraz z liczbami trafień dokumentuje log wyszukiwania w załączniku.

3.4. Kryteria włączenia i wykluczenia

Do korpusu włączano prace dotyczące metody, wiarygodności, powtarzalności i transparentności badań empirycznych lub roli AI w badaniach, niezależnie od dyscypliny. Wykluczano prace dotyczące wyłącznie treści merytorycznej swojej dziedziny bez związku z metodą oraz prace spoza tematu rozpoznawane po jednoznacznych markerach tytułu, takich jak modelowanie równań strukturalnych PLS-SEM, bazy biologiczne, zbiory do klasyfikacji tekstu, tematyka Metaverse czy czysto techniczne raporty modeli. Wykluczenia miały charakter wyłącznie tematyczny - nie językowy ani nie wynikający z roku publikacji. Typy prac włączonych do korpusu obejmowały artykuły recenzowane, przeglądy, preprinty i rozdziały książek, natomiast polityki instytucjonalne - na przykład zasady dostępności danych i kodu czasopism ekonomicznych - traktowano jako źródła instytucjonalne cytowane w tekście, nie jako pozycje samego korpusu.

3.5. Przesiew i deduplikacja

Przesiew prowadzono dwuetapowo. Etap pierwszy, przesiew tytułów, zastosował deterministyczną regułę słownikową: praca była włączana, jeśli jej tytuł zawierał frazę z którejś z rodzin słownictwa warstwowego, przy nadrzędnej regule, że praca powiązana z co najmniej dwiema kotwicami jest zawsze włączana. Wybór reguły deterministycznej zamiast klasyfikacji przez model językowy był świadomy - reguła słownikowa jest w pełni odtwarzalna, zapisywalna w załączniku i wolna od zmienności między uruchomieniami, co pozostaje spójne z samą tezą artykułu o odtwarzalności decyzji badawczych. Etap drugi, przesiew abstraktów, objął prace, których tytuł nie zawierał frazy kluczowej (warstwa Tier C); dla nich pobrano abstrakty z OpenAlex i zastosowano tę samą rodzinę reguł słownikowych, rozszerzoną o słownictwo widoczne dopiero w abstrakcie. Prace bez sygnału tematycznego po obu etapach odłożono jako odsiane, nie usuwając ich jednak z rejestru. Pełny przepływ ilościowy przedstawia Rysunek 1.



Rysunek 1. Budowa korpusu - scoping review metodologii SDD (v3, po przesiewie abstraktów).

Źródło: opracowanie własne.

3.6. Schemat kodowania

Prace zakwalifikowane jako rdzeń korpusu kodowano według szesnastopolowego schematu, obejmującego między innymi rodzaj problemu wiarygodności, mechanizm kontroli, moment kontroli - przed danymi, przed analizą, w trakcie analizy, w trakcie pisania, przy zgłoszeniu - jednostkę zamrożenia (hipoteza, plan analizy, dane, kod, artefakt, manuskrypt, prompt), rolę człowieka i rolę AI, proveniencję danych, kodu i AI, podejście do eksploracji, confirmacji i odchylenia od planu, transferowalność do ekonomii i finansów oraz potencjalny import danego elementu do proponowanej ramy. Pełną specyfikację pól zawiera schemat kodowania w załączniku. Kodowanie pól interpretacyjnych opiera się na pełnych tekstach i podlega adjudykacji przez człowieka, natomiast pola wywiedzione z metadanych - identyfikator, typ źródła, rok - wypełniano automatycznie.

3.7. Ograniczenia metody

Metoda ma pięć głównych ograniczeń, które wpływają na interpretację wyników:

1. Substytucja baz komercyjnych przez OpenAlex mogła pominąć prace indeksowane wyłącznie w Scopus, Web of Science lub EconLit, choć praktyczne pokrycie OpenAlex jest szerokie.
2. Przesiew słownikowy, wybrany dla odtwarzalności, z definicji nie wychwytuje prac trafnych tematycznie, lecz opisanych innym słownictwem; część takich prac pozostaje w warstwie odsianej i nie wchodzi do rdzenia.
3. Przypisanie warstwy na etapie przesiewu jest wstępne i wrażliwe na kolejność sprawdzania rodzin fraz - ostateczne przypisanie następuje dopiero z pełnego tekstu na etapie kodowania.
4. Warstwa polityk data/code w ekonomii (L5) jest w korpusie najcieńsza, co odzwierciedla zarówno realny rozkład literatury, jak i granice wyszukiwania słownikowego; pokrycie ekonomiczne raportujemy dodatkowo miarą niezależną od etykiety warstwy, czyli liczbą prac z czasopism ekonomicznych.

5. Przegląd nie dostarcza ilościowej syntezy siły dowodu, jak metaanaliza, ponieważ heterogeniczność korpusu to uniemożliwia; wnioski mają charakter mapujący i porządkujący, a ich status jest odpowiednio ograniczony w rozdziale 8.

Wszystkie pięć ograniczeń jest jawnie zadeklarowanych, zgodnie z zasadą przejrzystości, której dotyczy sam artykuł. Tak przeprowadzony przegląd stanowi podstawę empiryczną dla mapy podejść i warstw L1-L7, których charakterystyce poświęcony jest rozdział 4.

3.8. Deklaracja użycia narzędzi AI

Niniejszy przegląd powstał z udziałem narzędzi AI, którego zakres deklarujemy jawnie - zgodnie zarówno z polityką czasopisma wobec treści generowanych przez AI, jak i z własnym postulatem artykułu o rozliczalności udziału AI (warstwa L6). Agent badawczy Claude Science (zbudowany na modelu Claude Opus 4.8) był głównym wykonawcą warstwy technicznej: budowy i przesiewu korpusu, rusztowania i wypełniania arkusza kodowania z cytatem i poziomem pewności dla każdego pola, redakcji narracyjnej rozdziałów w obu językach oraz budowy obiektów i pakietów zgłoszeniowych. Drugim, niezależnym koderem w walidacji spójności kodowania był model z rodziny GPT (GPT 5.6 Terra), uruchomiony bez dostępu do kodów pierwotnych. Osobny model rozumujący (Claude Opus 4.8) pełnił role pomocnicze - sędziego semantycznego oceniającego równoważność opisów słownych oraz kodera podpróbki ekonomicznej.

Wszystkie decyzje merytoryczne pozostały po stronie autora jako jawne bramy zatwierdzania: zamrożenie pytań badawczych i zakresu, rozstrzygnięcia projektowe, rozstrzyganie rozbieżności między koderami, akceptacja treści każdego rozdziału oraz decyzja o zgłoszeniu. AI nie miało dostępu do kont zewnętrznych ani prawa przejścia bramy bez zatwierdzenia. Twierdzenia weryfikowano względem źródeł - każdy cytat w kodowaniu sprawdzono programowo wobec tekstu, a niską zgodność dwóch modeli traktowano jako sygnał kierujący uwagę autora, nie jako dowód poprawności. Wymienione narzędzia AI nie są i nie mogą być autorami pracy; pełną odpowiedzialność za jej treść ponosi autor. Wersje narzędzi i modeli, wraz z rolami i bramami, zestawia log proveniencji w pakiecie replikacyjnym.

4. Sześć podejść kontroli wiarygodności

4.0 Wprowadzenie: sześć odpowiedzi na jeden problem

Problem zarysowany we wcześniejszych rozdziałach - że droga od danych do wyniku kryje setki decyzji analitycznych, z których raportuje się zwykle tylko tę kombinację, która „wyszła” - nie jest nowy. Nauka wypracowała na niego szereg odpowiedzi, lecz każda z nich powstała w innej dyscyplinie, w innej dekadzie i pod inną nazwą. Niniejszy rozdział mapuje sześć takich podejść jako warstwy kontroli wiarygodności (L1-L6), opisując dla każdej z nich, co zamraża - jaką decyzję czyni nieodwracalną albo jawną - w którym momencie cyklu badania interweniuje oraz czego z założenia nie obejmuje. Ten ostatni element jest kluczowy dla tezy artykułu: żadna pojedyncze podejście nie pokrywa całego procesu, a granice między nimi wyznaczają lukę, którą rama SDD ma wypełnić w rozdziale 6.

Warstwowanie prac przypisano na podstawie pełnego tekstu, nie samego tytułu - kodowanie 28 prac tej mapy przekrojowej według 16 pól interpretacyjnych, opisane w rozdziale 3, zestawiono w Tabeli 4.1 (osobną podpróbkę 13 prac ekonomicznych, dokodowaną tym samym schematem, omawia rozdział 7).

Tabela 2. Sześć podejść kontroli wiarygodności: co zamraża, kiedy, czego nie obejmuje.

Warstwa	Podejście	Co zamraża	Kiedy	Czego nie obejmuje	Prace (korpus)	n
L1	Preregistracja / PAP / registered reports	Plan analizy: hipotezy, definicje zmiennych, specyfikacje regresji	Przed analizą (plan zarchiwizowany przed odśledzeniem danych)	Reprodukowalności obliczeniowej pipeline'u; pochodzenia i interoperacyjności artefaktów; rozliczalności udziału AI	Olken 2015; Ofosu&Posner 2020 (Do PAP Hamper Publication); Hagger i in. 2016; McKiernan i in. 2016	4
L2	Multiverse / specification curve / MHT	Rodzina hipotez i procedura testowa (kontrola multiplicity)	W trakcie analizy (korekcja przy wnioskowaniu)	Momentu prespecyfikacji (timing); pakowania i udostępniania artefaktów; zachęt instytucjonalnych	Benjamini&Yekutieli 2001; List/Shaiikh/Xu 2016	2
L3	Reprodukowalność / research compendia	Artefakt/ kod/ środowisko obliczeniowe do ponownego wykonania	W trakcie i po analizie (odtwarzalność wyniku)	Czy pierwotne decyzje były prespecyfikowane (można wiernie odtworzyć wynik p-hackowany); zachęt do dzielenia	OSC 2015; Munafo i in. 2017; Singularity 2017; ARIA 2025	4
L4	FAIR / provenance / RO-Crate	Dane + metadane + workflow jako znajdowalny, reużywalny artefakt	Przy publikacji/ udostępnianiu (pakowanie artefaktu)	Czy analizę prespecyfikowano; kontroli multiplicity; realnej zachęty, by dzielić	Wilkinson i in. 2016 (FAIR); Bechhofer 2010 (RO); RO-Crate 2022; FAIR workflows 2025; CARE 2020	5
L5	Polityki data/code / replication packages / bodźce	Manuskrypt/ depozyt danych przy zgłoszeniu; kryteria oceny badaczy	Przy zgłoszeniu i w ocenie downstream (egzekucja czasopisma/ instytucji)	Wewnętrznej dyscypliny analitycznej (zamrożenia decyzji); technicznej reprodukowalności pipeline'u	Hong Kong 2020; Wallis 2013; Open Innovation 2020; CLDF 2018; Christensen/Miguel 2019; Giofre i in. 2017	6
L6	AI-for-science / LLM agents / spec-driven AI	Prompt / przestrzeń narzędzi / template - zamrożona przestrzeń akcji agenta	W trakcie analizy (pętla wykonania) + checkpointy człowieka/ recenzja	Dyscypliny multiplicity; prerejestracji hipotez; governance danych - chyba że jawnie dołączone	Coscientist 2023; ChemCrow 2024; Agent Laboratory 2025; AI Scientist 2024; LLM-chem review 2024; LLM-ABM 2024	6
L7	Bodźce publikacyjne / result-blind review (wkład SDD)	Kryterium akceptacji oparte na jakości pytania i planu, nie na wyniku	Przed zebraniem wyników (recenzja etapu 1) - warstwa spinająca	Nie jest osobnym podejściem z korpusu - to warstwa, którą SDD dodaje na wierzchu L1-L6	(pochodna registered reports L1 + polityk L5; nie osobno kodowana)	0

Źródło: opracowanie własne.

4.1 L1 - Preregistracja, plany analiz, registered reports

Kontrola u źródła czasowego zamraża hipotezy i plan analizy, zanim badacz zobaczy wyniki. Kanonicznym mechanizmem jest pre-analysis plan (PAP) - prespecyfikacja zmiennych, reguł czyszczenia danych i specyfikacji regresji, zarchiwizowana z sygnaturą czasową przed analizą odślepionych danych. Olken (2015) formułuje pełną analizę kosztów i korzyści takiego zamrożenia w ekonomii, wprost rozróżniając część confirmacyjną - prespecyfikowaną, o rygorze prób klinicznych FDA - od eksploracyjnej, jawnie oznaczonej i poddanej niższemu rygorowi [10.1257/jep.29.3.61]. Ofosu i Posner (2020) pokazują z kolei, że koszt publikacyjny stosowania PAP jest znośny, co obala główny argument przeciwko jego adopcji [10.1257/pandp.20201079].

Zamrożenie planu można egzekwować także zbiorowo. Registered Replication Report Haggera i in. (2016) rozpisuje jeden ustandaryzowany protokół na 23 laboratoria, gdzie prerejestracja pełni funkcję kontraktu między ośrodkami - jest to silna forma L1 dostosowana do replikacji wielolabowych [10.1177/1745691616652873].

Podejście to nie obejmuje jednak reprodukowalności obliczeniowej samego pipeline'u - plan może zostać dotrzymany, a kod pozostać nieodtwarzalny - ani pochodzenia i interoperacyjności artefaktów, ani rozliczalności udziału AI. L1 dyscyplinuje intencję badacza, nie wykonanie analizy.

4.2 L2 - Multiple testing, multiverse, specification curve

Nawet przy uczciwym planie część decyzji pozostaje ukryta: przestrzeń możliwych analiz. Gdy z tych samych danych da się policzyć setki uprawnionych specyfikacji, sama liczba testów zawyża odsetek fałszywych odkryć. Odpowiedzią jest formalna kontrola multiplicity. Benjamini i Yekutieli (2001) dostarczają fundamentu statystycznego w postaci procedury kontrolującej False Discovery Rate z dowodem ważności przy zależności PRDS, co czyni ją stosowalną poza wyidealizowaną niezależnością testów [10.1214/aos/1013699998]. List, Shaikh i Xu (2016) przenoszą to myślenie wprost do ekonomii eksperymentalnej, podając procedury korekcji familywise error rate dla trzech scenariuszy wielokrotnego testowania [NBER w21875, 10.3386/w21875].

L2 nie sięga jednak momentu prespecyfikacji - korekcja działa na etapie wnioskowania, nie zabezpiecza timingu decyzji - ani pakowania i udostępniania artefaktów, ani zachęt do stosowania samej kontroli. Ta warstwa dyscyplinuje przestrzeń testów, nie ich kolejność ani trwałość.

4.3 L3 - Reprodukowalność i research compendia

Zamrożenie artefaktu, kodu i środowiska obliczeniowego pozwala odtworzyć wynik. Empirycznym punktem zapalnym była praca Open Science Collaboration (2015): bezpośrednia replikacja 100 badań psychologicznych wykazała, że efekty replikacji są średnio o połowę słabsze od oryginałów, a cały proces oparto na prerejestrowanym protokole i niezależnym audycie analiz w R, ustanawiając wzorzec audytowalnego pipeline'u replikacji [10.1126/science.aac4716]. Munafò i in. (2017) porządkują odpowiedź w programową mapę reform obejmującą pięć kategorii - metody, raportowanie, reprodukowalność, ewaluację i zachęty - czyli katalog mechanizmów, które rama SDD ma docelowo operacjonalizować [10.1038/s41562-016-0021]. Warstwę techniczną domyka Singularity (Kurtzer i in. 2017): kontener kapsułkujący całe środowisko obliczeniowe, tak by te same obliczenia wykonały się identycznie na innej maszynie [10.1371/journal.pone.0177459].

W tej warstwie pojawia się też praca najbliższa tezie artykułu - ARIA (2025), spec-driven, human-in-the-loop framework, w którym badacz definiuje specyfikację w języku naturalnym, a AI generuje i waliduje kod. ARIA jest z natury pracą złożoną: zakodowano ją przy L3 jako reprodukowalny pipeline spec→wykonanie, ale jednocześnie realizuje L6 jako rozliczalny udział

AI z human-in-the-loop - sama stanowi więc miniaturę kompozycji warstw, którą postuluje rama SDD, i wraca jako bezpośredni wzorzec architektoniczny w rozdziale 6 [arXiv:2510.11143].

Granica tej warstwy ma jednak kluczowe znaczenie dla całej mapy: sam mechanizm reprodukowalności - kontener, compendium - nie chwyta, czy pierwotne decyzje analityczne były prespecyfikowane, a **wynik uzyskany przez p-hacking odtwarza się równie wiernie jak wynik uczciwy**. Reprodukowalność obliczenia to nie to samo co jego bezstronność. Warto przy tym odnotować zastrzeżenie płynące wprost z danych: dwie z czterech prac tej warstwy - OSC (2015) i Munafò i in. (2017) - zamrażają także plan analizy, łącząc L3 z L1. Nie osłabia to granicy mechanizmu, lecz pokazuje, że najsilniejsze prace domykają ją, dokładając warstwę L1 - wątek rozwinięty dalej w rozdziale 5.2.

4.4 L4 - FAIR, research objects, provenance

Dane i workflow zostają zamrożone jako znajdowalny, opisany i reużywalny artefakt. Wczesnym sformułowaniem są Research Objects Bechhofera i in. (2010): semantycznie bogata agregacja danych, metod i ludzi jako jednostka wiedzy, w miejsce liniowego, czytelnego tylko dla człowieka artykułu [10.1038/npre.2010.4626.1]. Zasady FAIR (Wilkinson i in. 2016) kodyfikują to w cztery wymiary - Findable, Accessible, Interoperable, Reusable - rozciągnięte świadomie z danych na algorytmy i workflow, z framingiem „maszyna jako interesariusz” [10.1038/sdata.2016.18]. Dojrzałą implementacją jest RO-Crate (Soiland-Reyes i in. 2022): pakowanie artefaktów z metadanymi w Schema.org/JSON-LD, będące kandydatem na kontener pakietu badawczego [10.3233/ds-210053]. Wilkinson i in. (2025) domykają warstwę, stosując FAIR wprost do computational workflows - czyli traktując sam pipeline analityczny jako obiekt FAIR - co dotyczy rdzenia SDD [10.1038/s41597-025-04451-9]. Zasady CARE (Carroll i in. 2020) dokładają natomiast wymiar governance, a więc pytanie o to, kto ma autorytet kontroli danych i jak dzielić z niego wynikające korzyści - czego czysto techniczne FAIR nie obejmuje [10.5334/dsj-2020-043].

L4 nie rozstrzyga jednak, czy analizę prespecyfikowano, nie kontroluje multiplicity ani nie tworzy realnej zachęty, by artefakt w ogóle udostępnić. Czyni artefakt trwałym i opisanym, ale nie czyni go ani bezstronnym, ani rzeczywiście udostępnionym.

4.5 L5 - Polityki data/code, replication packages, bodźce

Kontrola przenosi się z rąk pojedynczego badacza na instytucje egzekwujące - czasopisma, repozytoria, systemy oceny. Wallis, Rolando i Borgman (2013) pokazują realia „długiego ogona” nauki: badacze są gotowi dzielić się danymi, ale rzadko są o to proszeni, brakuje repozytoriów i zachęt, a samo udostępnianie nie wystarcza bez egzekucji [10.1371/journal.pone.0067332]. Że egzekucja działa, dowodzą dwie kolejne prace. Giofrè i in. (2017) mierzą, jak wytyczne czasopisma - nowa statystyka, badge’ę open science - realnie zwiększyły dostępność danych i materiałów [10.1371/journal.pone.0175583], a Christensen, Dafoe, Miguel i in. (2019) wykorzystują polityki danych jako naturalny eksperyment, wykazując mierzalny wpływ dzielenia się danymi na cytowania - ekonometryczny argument za mechanizmami L4/L5 [10.1371/journal.pone.0225883]. Od strony zachęt Hong Kong Principles (Moher i in. 2020) domagają się, by systemy oceny badaczy nagradzały integralność - bez tego mechanizmy kontroli po prostu nie są stosowane [10.1371/journal.pbio.3000737]. CLDF (Forkel i in. 2018) dostarcza konkretnej implementacji standardu formatu z walidatorem i ontologią [10.1038/sdata.2018.205], a rama Open Innovation in Science (Beck i in. 2020) osadza to wszystko w organizacji nauki jako całości [10.1080/13662716.2020.1792274].

Ta warstwa nie sięga jednak wewnętrznej dyscypliny analitycznej - polityka wymusza depozyt, nie bezstronność analizy - ani technicznej reprodukowalności pipeline'u. L5 dyscyplinuje udostępnianie i zachęty, nie treść samej analizy.

4.6 L6 - AI-for-science, agenci LLM, spec-driven AI

Najmłodsza z warstw jako jedyna adresuje ryzyko, którego pięć poprzednich nie przewidywało: udział AI jako element metody wymagający proveniencji. Coscientist (Boiko i in. 2023) definiuje modularny system promptów z jawną przestrzenią akcji (GOOGLE/PYTHON/DOCUMENTATION/EXPERIMENT) i logowaniem decyzji, traktując prompt jako zamrożoną jednostkę [10.1038/s41586-023-06792-0]. ChemCrow (Bran i in. 2024) dodaje agenta LLM z 18 eksperckimi narzędziami, jawnym łańcuchem rozumowania Thought/Action/Observation oraz narzędziami bezpieczeństwa, ustanawiając wzorzec rozliczalnego agenta [10.1038/s42256-024-00832-8]. Agent Laboratory (Schmidgall i in. 2025) wbudowuje checkpointy człowieka na każdym etapie, pokazując, że udział człowieka istotnie poprawia jakość [arXiv:2501.04227]. Skrajnym przypadkiem pozostaje The AI Scientist (Lu i in. 2024) - pełna autonomia z automatycznym recenzentem - którego jawnie raportowane ryzyka, takie jak halucynacja całych wyników czy import nieznanych bibliotek, same uzasadniają potrzebę zamrożenia i audytu [arXiv:2408.06292]. Dwa przeglądy, Ramos, Collison i White (2024) [10.1039/d4sc03921a] oraz Gao i in. (2024) [10.1057/s41599-024-03611-3], mapują przestrzeń agentów i wskazują human alignment oraz ewaluację jako otwarte wyzwania rozliczalności.

L6 nie obejmuje dyscypliny multiplicity, prerejestracji hipotez ani governance danych, chyba że zostaną one jawnie dołączone. Dyscyplinuje udział AI, ale sama nie dziedziczy zabezpieczeń warstw L1-L5.

4.7 Warstwa przekrojowa: diagnoza problemu

Poza sześcioma warstwami korpus zawiera pracę, która nie jest warstwą kontroli, lecz diagnozą problemu, jaki wszystkie sześć próbuje rozwiązać. Ioannidis (2005) pokazuje modelem probabilistycznym, że wartość predykcyjna dodatnia wyniku zależy od mocy testu, poziomu istotności i pre-study odds - a więc że pojedyncze $p < 0,05$ z jednego badania jest niewystarczające [10.1371/journal.pmed.0020124]. To motywacja dla całej mapy zaproponowanej w tym rozdziale: gdyby pojedynczy test wystarczał, żadna z warstw L1-L6 nie byłaby w ogóle potrzebna.

Sześć podejść opisanych powyżej powstało niezależnie od siebie, adresując kolejno inny moment procesu badawczego - od prerejestracji hipotezy, przez kontrolę przestrzeni testów i reprodukowalność obliczeniową, po governance danych i rozliczalność AI. Rozdział 5 pokazuje, jak te warstwy współwystępują w praktyce badawczej i gdzie w tej mozaice pozostają luki, których żadna pojedyncze podejście nie zamyka.

5. Synteza porównawcza

Rozdział 4 przedstawił sześć podejść kontroli epistemicznej osobno, każdą w jej własnej logice historycznej i metodologicznej. Rozdział niniejszy zestawia je w jednej macierzy porównawczej, by odpowiedzieć na dwa pytania postawione we wstępie: jaki mechanizm kontroli jest im wspólny (RQ2) i czego razem nie obejmują (RQ3). Teza artykułu głosi, że luka nie leży wewnątrz żadnej z warstw, lecz między nimi - i że da się ją pokazać, nie tylko postulować.

5.1 Wspólny mechanizm: zamrożenie decyzji jako obiektu audytowalnego

Zestawione obok siebie, sześć podejść ujawnia jeden wzorzec. Każde czyni pewną decyzję nieodwracalną albo jawną w określonym momencie cyklu badania, tak by nie dało się jej po cichu zmienić pod wynik: L1 zamraża intencję - hipotezy, plan badania - jeszcze przed zebraniem danych; L2 zamraża przestrzeń testów, czyli rodzinę hipotez i procedurę korekcji, w momencie wnioskowania; L3 zamraża wykonanie, a więc kod i środowisko obliczeniowe, tak by było odtwarzalne; L4 zamraża artefakt - dane i workflow - jako opisany i trwały obiekt; L5 zamraża udostępnienie, czyli depozyt i kryteria oceny, poprzez egzekucję instytucjonalną; L6 zamraża wreszcie udział AI, rozumiany jako prompt i przestrzeń narzędzi, jako jednostkę logowaną. Wspólnym mianownikiem tych sześciu mechanizmów jest zamrożenie decyzji jako obiektu, który da się później zaudytować - różnią się one jedynie tym, którą decyzję zamrażają i w którym momencie cyklu badawczego. Wzorzec ten staje się czytelny dopiero w zestawieniu podejście × wymiar kontroli - co dana warstwa zamraża, kiedy, jak audytuje i czego nie obejmuje - które porządkuje Tabela 3.

Tabela 3. Macierz syntezy: sześć podejść według wymiaru kontroli (co zamraża / kiedy / jak audytuje / czego nie obejmuje).

Warstwa	Co zamraża	Kiedy	Jak audytuje	Czego NIE obejmuje
L1 Preregistracja / PAP	Intencja: hipotezy, plan analizy	Przed danymi	Plan zarchiwizowany vs raport	reprodukowalność, artefakty, AI
L2 Multiverse / MHT	Przestrzeń testów: rodzina hipotez	Przy wnioskowaniu	Skorygowane p / krzywa specyfikacji	timing prespec., pakowanie, bodźce
L3 Reprodukowalność / compendia	Wykonanie: kod, środowisko	W trakcie i po analizie	Ponowne wykonanie kodu	czy decyzje prespec. (p-hacking się odtwarza)
L4 FAIR / provenance	Artefakt: dane+metadane+workflow	Przy udostępnianiu	Metadane provenance, graf workflow	prespecyfikacja, multiplicity, bodźce
L5 Polityki data/code / bodźce	Udostępnienie: depozyt, kryteria oceny	Przy zgłoszeniu i downstream	Egzekucja instytucji (data editor)	wewn. dyscyplina analit., reprodukowalność
L6 AI-for-science / agenci LLM	Udział AI: prompt, przestrzeń narzędzi	W pętli wykonania + checkpointy	Log promptów/ akcji agenta	multiplicity, prerejestracja, governance

Źródło: opracowanie własne.

5.2 Warstwy nie są rozłączne - i to jest wskazówka

Kodowanie korpusu ujawniło rzecz istotną dla tezy artykułu: część prac należy do więcej niż jednej warstwy naraz. Dwie z czterech prac zaklasyfikowanych jako L3 (Open Science Collaboration 2015; Munafò i in. 2017) zamrażają nie tylko kod, ale i plan analizy, łącząc w ten sposób L1 z L3. FAIR (Wilkinson i in. 2016) rozciąga się z danych na workflow, dotykając już L3. CARE (Carroll i in. 2020) dokłada do L4 wymiar governance właściwy L5. Coscientist i ChemCrow, zaklasyfikowane jako L6, wbudowują z kolei logowanie proveniencji, które z ducha należy do L4.


To nie jest szum kodowania, lecz sygnał. Najlepsze prace już komponują warstwy, ponieważ pojedyncza z nich nie wystarcza - kompozycja dzieje się jednak ad hoc, w obrębie jednej pracy czy

jednego narzędzia, bez wspólnej architektury. Teza SDD, rozwinięta w rozdziale 6, jest uogólnieniem tej obserwacji: skoro warstwy i tak trzeba łączyć, należy złożyć je świadomie w jeden workflow, zamiast pozostawiać tę kompozycję przypadkowi.

5.3 Cztery braki widoczne z macierzy

Kolumna „czego nie obejmuje” w macierzy, czytana w pionie, pokazuje cztery decyzje, których żadna z sześciu warstw nie zamraża systematycznie. Pierwszą jest proveniencja AI: tylko L6 w ogóle podejmuje udział sztucznej inteligencji, i to jako wątek świeży i niedojrzały, bo pięć starszych warstw powstało, zanim prompty, modele i agenci stały się częścią metody - prompt jako logowana, wersjonowana jednostka po prostu nie ma miejsca w L1-L5. Drugą jest dyscyplina twierdzeń: żadna warstwa nie wiąże języka wniosków ze statusem dowodu, a Ioannidis (2005) diagnozuje wprowadzenie skutku takiego stanu rzeczy - nadinterpretację pojedynczego $p < 0,05$ - lecz żadne z podejść nie zamraża reguły, że twierdzenie nie może być mocniejsze niż stojący za nim artefakt. Trzecią jest budowa tekstu z artefaktów: L3-L4 czynią artefakty odtwarzalnymi i opisanymi, ale manuskrypt wciąż powstaje obok wyników, jako osobny tekst przepisywany ręcznie, i nikt nie zamraża zależności, w której liczba w zdaniu odpowiada liczbie w artefakcie. Czwartą wreszcie są bramy zatwierdzania przez człowieka: L6, na przykładzie Agent Laboratory, pokazuje checkpointy człowieka jako pojedynczy przypadek, lecz nie istnieje podejście, która czyniłaby jawną bramę decyzji człowiek/AI stałym elementem architektury.

Te cztery braki nie są opinią autora - wynikają wprost z pustych pól macierzy i stanowią specyfikację tego, co rama SDD musi dołożyć, co jest przedmiotem rozdziału 6. Interpretacja pustych pól jako luk zakłada zarazem, że korpus jest reprezentatywny dla każdego z podejść - jest to ograniczenie doboru słownikowego, omówione w §3.7 i rozdziale 8. Mapa siedmiu warstw kontroli epistemicznej, przedstawiona na Rysunku 5.1, pokazuje te braki jako obszar, który dopiero warstwa siódma - bodźce publikacyjne i result-blind review - wraz z architekturą SDD, domyka.



Rysunek 2. Mapa siedmiu warstw kontroli epistemicznej: gdzie w cyklu badania każde podejście zamraża decyzje.

Źródło: opracowanie własne.

5.4 Odpowiedź na obawę recenzenta

Najmocniejszy zarzut, jaki można postawić wobec artykułu, brzmi: to tylko preregregistracja plus reprodukowalność pod nową nazwą. Macierz jest na niego odpowiedzialna. Preregistracja (L1) nie zamraża kodu ani udziału AI; reprodukowalność (L3) nie zamraża intencji ani języka twierdzeń; razem oba podejścia nie obejmują żadnego z czterech braków omówionych w §5.3. To, co dokłada SDD, nie jest zatem przeetykietowaniem istniejących praktyk, lecz złożeniem sześciu warstw w jeden workflow wraz z czterema brakującymi zamrożeniami. Rozwinięcie tej oryginalności - i szczegółowy opis architektury, która ją realizuje - jest treścią rozdziału 6.

6. Rama SDD: spec-driven AI dla badań empirycznych

Teza rozdziału

Rozdział 5 pokazał, że sześć podejść dzieli jeden mechanizm - zamrożenie decyzji jako obiektu audytowalnego - i zostawia cztery braki: proveniencję AI, dyscyplinę twierdzeń, budowę tekstu z artefaktów oraz bramy człowieka. Ten rozdział przedstawia spec-driven development (SDD) dla badań empirycznych jako **architekturę kontroli epistemicznej**, która składa sześć warstw w jeden wykonywalny workflow i dokłada czwórkę brakujących zamrożeń jako siódmą warstwę. Kluczowe rozróżnienie, do obrony przed recenzentem, brzmi: SDD **nie jest** nową techniką pojedynczej warstwy - jest kompilatorem, który czyni wykonywalnym to, co podejścia osiągały rozproszone i ad hoc.

Siedem warstw kontroli epistemicznej

SDD organizuje kontrolę w siedem warstw. Sześć pierwszych to podejścia omówione w rozdziale 4, przełożone z osobnych praktyk na współrzędne jednej architektury; siódma jest wkładem własnym ramy.

- **L1 intencja** - spec zamraża hipotezy i plan analizy przed danymi (dziedziczy z preregregracji/PAP).
- **L2 przestrzeń analiz** - spec deklaruje rodzinę testów i regułę korekcji multiplicity (dziedziczy z multiverse/MHT).
- **L3 wykonanie** - pipeline i środowisko zamrożone jako odtwarzalne (dziedziczy z reproducible research).
- **L4 artefakt** - dane, kod i workflow pakowane z proveniencją i trwałym ID (dziedziczy z FAIR/RO-Crate).
- **L5 udostępnienie** - pakiet submission zgodny z politykami czasopism i egzekucją (dziedziczy z data/code policies).
- **L6 udział AI** - prompty, modele i agenci logowani i wersjonowani jako elementy metody (dziedziczy z AI-for-science).
- **L7 bodźce** - kryterium akceptacji oparte na jakości pytania i planu, nie na wyniku (result-blind / registered reports jako warstwa spinająca).

Ponad to dziedziczenie SDD dokłada cztery zamrożenia, których żadna warstwa nie miała samodzielnie (por. §5.3): proveniencję AI jako obowiązkowy artefakt, a nie opcję; dyscyplinę twierdzeń, w której język wniosku jest związany ze statusem dowodu; deterministyczną budowę tekstu z artefaktów, gdzie liczba w zdaniu odpowiada liczbie w artefakcie; oraz jawne bramy

zatwierdzania człowiek/AI między etapami. Tabela 4 zestawia każdą warstwę z tym, co SDD dokłada ponad podejścia L1-L6.

Tabela 4. Siedem warstw kontroli epistemicznej w ramie SDD i to, co SDD dokłada ponad każde podejście.

Warstwa	Wymiar	Podejście	Co SDD dokłada
L1	Intencja	Preregistracja / PAP	spec jako wykonywalny artefakt wejściowy
L2	Przestrzeń analiz	Multiverse / MHT	deklaracja rodziny testów w specu
L3	Wykonanie	Reproducible research	pipeline spięty ze specem i logiem AI
L4	Artefakt	FAIR / RO-Crate	artefakt = źródło każdego twierdzenia
L5	Udostępnienie	Data/code policies	pakiet submission generowany z inventory
L6	Udział AI	AI-for-science	proweniencja AI OBOWIĄZKOWA, nie opcja
L7	Bodźce	result-blind / reg. reports	kryterium akceptacji = jakość planu


Źródło: opracowanie własne.

Minimalny workflow: siedem etapów z bramami

Architektura warstwowa staje się metodą dopiero wtedy, gdy przełoży się ją na kolejność etapów z bramami zatwierdzania. Minimalny workflow SDD obejmuje siedem etapów:

1. **Idea** - pytanie badawcze i teza w języku naturalnym (spec wejściowy).
2. **Design freeze** - zamrożenie hipotez, planu analizy i przestrzeni testów (L1+L2); brama człowieka przed dostępem do danych.
3. **Data freeze** - zamrożenie snapshotu danych z proveniencją źródła i definicjami (L4); dla danych wtórnych: wersja vendora, data pobrania, reguły rewizji.
4. **Analysis artifacts** - wykonanie pipeline'u w zamrożonym środowisku; każdy wynik jest artefaktem z logiem, w tym logiem promptów i modeli AI (L3+L6).
5. **Inventory** - inwentaryzacja artefaktów: co powstało, z czego, jakim narzędziem; brama dyscypliny twierdzeń, w której każde twierdzenie wskazuje artefakt.
6. **Manuscript build** - deterministyczne złożenie manuskryptu z artefaktów, gdzie liczby, tabele i rysunki są wstawiane z inventory, nie przepisywane ręcznie.
7. **Submission package** - pakiet zgodny z polityką docelową (L5) wraz z pełną proveniencją; brama człowieka przed wysłaniem.

Między etapami 2/3, 3/4 i 5/6 stoją jawne bramy człowieka - miejsca, w których badacz zatwierdza przejście, a AI nie może go ominąć: przed dostępem do danych, po zamrożeniu planu; przed uruchomieniem pipeline'u, po zamrożeniu danych; oraz przed budową manuskryptu, po inwentaryzacji artefaktów. To operacjonalizuje human-in-the-loop, który w warstwie L6 - u Agent Laboratory czy ARIA - pojawiał się jako pojedynczy przykład, tu zaś funkcjonuje jako stały element architektury, co obrazuje Rysunek 3.



Rysunek 3. Minimalny workflow SDD: siedem etapów z bramami zatwierdzania przez człowieka.

Źródło: opracowanie własne.

Wariant lekki i pełny

SDD nie zakłada, że każde badanie potrzebuje pełnej maszynarii. Wariant lekki ogranicza się do specu projektu (L1+L2), snapshotu danych (L4), skryptu odtwarzalnego (L3) oraz listy twierdzeń wskazujących artefakty, realizującej dyscyplinę twierdzeń - bez kontenerów i bez agentów AI; jest odpowiedni dla pojedynczego badacza, danych publicznych i prostej analizy. Wariant pełny obejmuje wszystkie siedem warstw wraz z kontenerem środowiska, logowaniem proveniencji AI, deterministyczną budową tekstu i pakietem submission - i to on odpowiada potrzebom zespołów, danych wrażliwych lub licencjonowanych oraz pipeline'ów z udziałem agentów LLM.

Oba warianty łączy jednak wspólny, nieusuwalny rdzeń trzech zamrożeń: plan przed danymi, artefakt jako źródło twierdzenia, proveniencja tego, co zrobiło AI. Reszta architektury skaluje się już z ryzyka konkretnego projektu.

Oryginalność jawnie odróżniona od L1-L6

To jest brama wkładu autora. Oryginalność SDD nie polega na wynalezieniu nowej warstwy, lecz na pięciu elementach, z których każdy jest nieobecny w podejściach rozpatrywanych osobno:

1. **Integracja na poziomie workflow.** SDD pokazuje, że L1-L6 to nie konkurencyjne szkoły, lecz współrzędne jednej architektury; kompozycja, która w korpusie dzieje się ad hoc (§5.2), staje się jawną, wykonywalną kolejnością etapów.
2. **Proveniencja AI jako obowiązek, nie opcja.** Prompt, model i agent są elementami metody wymagającymi logu na równi z kodem - czego pięć starszych warstw nie przewidywało.
3. **Budowa tekstu z artefaktów.** Manuskrypt jest deterministycznym produktem inventory, nie tekstem pisanym obok wyników, co zamyka lukę między odtwarzalnym artefaktem a ręcznie przepisaną liczbą.
4. **Dyscyplina twierdzeń.** Język wniosków jest jawnie ograniczony do statusu dowodu stojącego za twierdzeniem.
5. **Bramy człowieka jako architektura.** Zatwierdzanie człowiek/AI jest stałym elementem między etapami, a nie dobrą praktyką pozostawioną dyscyplinie badacza.

Żaden z tych pięciu elementów nie jest zamrażany systematycznie przez L1-L6, co potwierdzają puste pola macierzy z §5.3. Zarazem żaden nie jest „nowością z niczego” - każdy stanowi logiczne domknięcie kierunku, w którym podejścia już zmierzały. W tym właśnie sensie SDD jest syntezą na poziomie workflow, a nie osobnym wynalazkiem. Różnica między kompilatorem a techniką pojedynczej warstwy jest przy tym ścisła, nie retoryczna. Technika warstwy - jak specification

curve w L2 czy kontener w L3 - rozwiązuje jeden problem kontroli w jednym miejscu procesu i jest wymienna na inną technikę tej samej warstwy bez naruszenia reszty. Kompilator nie dodaje szóstej techniki obok nich, lecz ustala kolejność, zależności i bramy między warstwami tak, by wyjście jednej stawało się zamrożonym wejściem następnej: plan przed danymi, dane przed analizą, artefakt przed twierdzeniem. Wkład leży w kompozycji, nie w składnikach - te same techniki uruchomione bez wymuszonej kolejności i bram dają praktykę ad hoc, którą korpus pokazuje jako regułę, nie wyjątek. Osobno warto odróżnić warstwę L7 od registered reports, z których się wywodzi: registered reports są instytucją czasopisma, w której to redakcja zobowiązuje się ocenić i przyjąć badanie na podstawie planu przed zebraniem wyników, podczas gdy L7 w ramie SDD jest warstwą architektury badania, którą badacz może utrzymać niezależnie od tego, czy czasopismo docelowe oferuje taką ścieżkę. SDD nie zastępuje registered reports tam, gdzie są dostępne - operacjonalizuje ich zasadę jako warstwę działającą także bez nich.

Ograniczenia ramy

Uczciwość wobec testu spójności wymaga nazwania granic tej propozycji. Po pierwsze, SDD jest ramą, nie ewaluacją - niniejszy artykuł jest scoping review i nie dostarcza empirycznego dowodu, że stosowanie SDD podnosi reprodukowalność; to zadanie dla osobnego badania. Po drugie, istnieje koszt: pełny wariant dokłada narzut, który dla prostych badań może przewyższać korzyść, stąd potrzeba wariantu lekkiego. Po trzecie, proveniencja AI zależy od narzędzi, które szybko się zmieniają - rama specyfikuje *co* logować, nie *czym*, a ta abstrakcja może się z czasem zestarzeć.

Adaptacja ramy do ekonomii i finansów - do danych wtórnych, rynkowych i makroekonomicznych - jest przedmiotem rozdziału 7.

7. Zastosowanie w ekonomii i finansach

7.1 Dlaczego ekonomia i finanse są dobrym poligonem

Rozdziały 4-6 zbudowały ramę SDD na literaturze przekrojowej, warstwa po warstwie i podejście po podejściu. Ten rozdział przenosi ją do praktyki badawczej w ekonomii i finansach, odpowiadając na pytanie, dlaczego to właśnie tam rama zyskuje, a nie traci na precyzji. Ekonomia jest polem szczególnie sprzyjającym z trzech powodów. Ma już dojrzałą kulturę prerejestracji i polityk danych, więc adaptacja nie zaczyna się od zera. Jej dane są też w większości wtórne - rynkowe, makroekonomiczne, panelowe, pozyskiwane od dostawców - co przenosi ciężar kontroli z pytania „czy zebrano dane uczciwie” na pytanie „czy przetworzono je uczciwie”, a to dokładnie ten punkt, w którym działa SDD. Wreszcie korpus tego przeglądu obejmuje 71 prac z ekonomicznym venue na 582 zakwalifikowane pozycje - metrykę pokrycia wyprowadzoną z fazy 01-02 - w tym 19 zakodowanych prac z ekonomicznym venue (na 41 zakodowanych pełnym tekstem, dobór celowy wg warstw), które stanowią kotwice empiryczne dla całego rozdziału.

7.2 Preregistracja i rejestry w ekonomii jako górna brama

Ekonomia ma już własną, przemysłaną praktykę prerejestracji, którą SDD dziedziczy jako warstwę L1, nie wprowadza jej od podstaw. Olken (2015) dostarcza kanonicznej analizy tego mechanizmu: pre-analysis plan przeniesiony z prób klinicznych do ekonomii, z jawnym rozdzieleniem części confirmacyjnej - prespecyfikowanej - od eksploracyjnej, co wprost odpowiada architekturze górnej bramy SDD, czyli design freeze [10.1257/jep.29.3.61]. Głównym oporem przed adopcją takich planów był zawsze domniemany koszt publikacyjny, jednak Ofosu i Posner (2020), analizując

próbę praktyki czasopism top-5, pokazują, że koszt ten jest znośny, usuwając tym samym kluczowy argument przeciw preregistracji [10.1257/pandp.20201079]. Dla ekonomisty plan analizy zdeponowany w rejestrze - AEA RCT Registry, OSF - jest już gotową implementacją L1; SDD dokłada do niej tylko jeden wymóg: aby plan ten był wykonywalnym artefaktem wejściowym, a nie dokumentem istniejącym obok właściwej analizy. Podpróbka prac ekonomicznych dokodowana w tej fazie dokłada trzy pozycje wprost o pre-analysis plans. Banerjee, Duflo, Finkelstein, Katz, Olken i Sautmann (2020) argumentują przeciw zbyt sztywnej prespecyfikacji: plan powinien zamrażać część konfirmacyjną, ale nie tłumić eksploracji [10.3386/w26993] - co wprost wspiera architekturę SDD, w której część konfirmacyjna jest zamrożona, a eksploracyjna jawnie oznaczona, nie zaś wyeliminowana. Miguel (2021) daje syntetyczny przegląd adopcji otwartych danych, prerejestracji i polityk czasopism w ekonomii, ze świadectwem, że najgorsze obawy o koszty adopcji się nie ziściły [10.1257/jep.35.3.193]. Debata wokół wartości p (2023) pokazuje z kolei heterogeniczność reguł inferencji między czasopismami, motywując jawną deklarację reguły w specyfikacji na poziomie L1 i L7 [10.30430/gjae.2023.0231].

7.3 Kontrola wielości testów

Ekonomia eksperymentalna zmierzyła się z problemem researcher-degrees-of-freedom wcześniej niż wiele innych dyscyplin. List, Shaikh i Xu (2016) podają procedury korekcji familywise error rate dla trzech scenariuszy wielokrotnego testowania w eksperymentach ekonomicznych, co stanowi bezpośrednią realizację warstwy L2 w języku ekonometrii [10.3386/w21875]. Fundament statystyczny tej kontroli - metoda Benjaminiego-Yekutieliiego dla FDR, ważna przy zależności testów - jest w ekonometrii stosowany rutynowo przy screeningu wielu czynników [10.1214/aos/1013699998]. SDD nie wnosi tu żadnej nowej statystyki; wymaga jedynie, by rodzina testów i reguła korekcji były zadeklarowane w specyfikacji przed analizą, a nie dobrane dopiero po zobaczeniu wyników. Podpróbka dokłada dwie kotwice. Romano i Wolf (2005) podają kanoniczną krokową procedurę kontroli FWER dla danych finansowych - funduszy, modeli CAPM, miar VaR - jako sformalizowane data snooping, czyli realizację L2 w natywnym języku ekonometrii [10.1111/j.1468-0262.2005.00615.x]. Borusyak, Jaravel i Spiess (2024) rozdzielają natomiast estymand i założenia, zamrożone a priori, od samej estymacji, dostarczając działającego artefaktu-kodu - model warstw L2-L4 spiętych z górną bramą [10.1093/restud/rdae007].

7.4 Polityki AEA data/code jako dolna brama

Najbardziej rozwiniętym elementem infrastruktury kontroli w ekonomii jest polityka data/code czasopism oraz instytucja data editora, ugruntowana w AEA i Econometrica. To dojrzała warstwa L5 - dolna brama, przy której replication package staje się warunkiem publikacji. Że taka egzekucja realnie zmienia praktyki badawcze, dowodzą prace z korpusu: Giofrè i współautorzy (2017) mierzą wpływ wytycznych czasopisma na dostępność danych [10.1371/journal.pone.0175583], a Christensen, Dafoe, Miguel i inni (2019) - sami ekonomiści - wykorzystują polityki danych jako naturalny eksperyment, wykazując mierzalny wpływ dzielenia się danymi na cytowania [10.1371/journal.pone.0225883]. Kluczowa dla ramy jest jednak obserwacja, że polityka AEA jest bramą downstream, umieszczoną przy publikacji, podczas gdy SDD dokłada bramy upstream - przed danymi, przed analizą. Replication package sprawdza, czy wynik da się odtworzyć, ale nie sprawdza, czy decyzje analityczne były prespecyfikowane, a to ta sama granica, którą napotkaliśmy już przy warstwie L3 w rozdziale 4.3: pakiet AEA odtworzy p-hacking równie wiernie jak analizę przeprowadzoną uczciwie. Dwie prace z podpróbki dostarczają twardego dowodu na tę granicę. Chang i Li (2015) odtworzyli kluczowy wynik jedynie 33 procent z sześćdziesięciu badań bez kontaktu z autorami, a nawet z ich pomocą poniżej połowy [10.17016/

feds.2015.083] - świadectwo, że sama polityka depozytu nie wystarcza bez egzekucji i standaryzacji wykonywalnych artefaktów. Duvendack, Palmer-Jones i Reed (2017) pokazują z kolei, że ekonomia pozostaje w tyle za psychologią i politologią w kulturze replikacji [10.1257/aer.p20171031], co wzmacnia argument o potrzebie bram upstream, nie tylko downstream.

7.5 Upstream workflow dla danych finansowych i makroekonomicznych

Tu leży właściwy wkład tego rozdziału. Dane finansowe i makroekonomiczne niosą ryzyka, których standardowe polityki data/code nie chwytają, ponieważ są to ryzyka przetwarzania danych wtórnych, powstające przed analizą, a nie w momencie publikacji. SDD adresuje je na etapie data freeze, opisanym w rozdziale 6.2, a można je sprowadzić do czterech konkretnych mechanizmów.

- **Look-ahead bias** - użycie informacji, która nie była dostępna w momencie decyzji, na przykład danych skorygowanych wstecznie lub wskaźników opublikowanych później. Zamrożeniem, które temu zapobiega, jest snapshot danych z sygnaturą point-in-time: data, na którą dane były znane, a nie data ich pobrania.
- **Survivorship bias** - próba zawężona do podmiotów, które przetrwały (fundusze, spółki), ponieważ bazy danych usuwają podmioty wygasłe. Zamrożeniem jest tu jawna deklaracja uniwersum wraz z podmiotami, które wypadły, oraz reguły ich włączania do próby.
- **Rewizje danych** - szeregi makroekonomiczne, takie jak PKB czy zatrudnienie, są rewidowane po pierwszej publikacji, przez co analiza przeprowadzona na danych „ostatecznych” różni się od analizy na danych „real-time”. Zamrożeniem jest wersja vintage szeregu, pochodząca z bazy real-time, a nie jego bieżący odczyt.
- **Definicje dostawcy** - ten sam nominalnie wskaźnik różni się między dostawcami, na przykład Bloomberg, Refinitiv czy CRSP, a także między wersjami tego samego dostawcy. Zamrożeniem jest tu odnotowanie dostawcy, wersji definicji i daty ekstrakcji jako części proveniencji artefaktu danych.

Empirycznym fundamentem tego argumentu jest praca Menkvelda i współautorów (2024): 164 zespoły badawcze testowały te same hipotezy na tych samych danych, a rozbieżność ich wyników - nonstandard errors - okazała się większa niż standardowy błąd szacunku [10.1111/jofi.13337]. To mierzalny dowód, że stopnie swobody badacza generują niepewność, którą zamrożenie ścieżki analizy i dwuetapowy peer-feedback redukują - najsilniejsza kotwica empiryczna dla całego rozdziału. Wspólnym mianownikiem czterech ryzyk poniżej jest to, że każde z nich stanowi cichą decyzję o danych wejściowych, którą SDD czyni jawnym, zamrożonym artefaktem z udokumentowaną proveniencją - realizację warstwy L4 (artefakt danych), spiętą z górną bramą wymagającą decyzji człowieka przed rozpoczęciem analizy. Tabela 5 mapuje siedem warstw SDD na kolejne etapy badania prowadzonego na danych finansowych, wskazując konkretne zamrożenie i ryzyko, które ono adresuje.

Tabela 5. Odzworowanie warstw SDD na etapy workflow badania empirycznego w finansach.

Warstwa	Etap	Mechanizm	Zamraża	Ryzyko
L1	Design freeze	PAP w rejestrze (AEA/OSF)	rejestr PAP: hipotezy + plan	HARKing (hipotezy po wynikach)
L2	Design freeze	deklaracja rodziny testów	rodzina hipotez + korekcja MHT	zbyt wiele testów bez korekcji
L4	Data freeze	snapshot danych point-in-time	dostawca + wersja + data ekstrakcji	look-ahead, vendor definitions
L4	Data freeze	deklaracja uniwersum	podmioty wypadłe + reguła	survivorship bias
L4	Data freeze	wersja vintage szeregu	real-time database vintage	rewizje danych makro
L3	Analysis artifacts	kontener + pipeline	środowisko + kod ekonometryczny	nieodtworzalne obliczenia
L6	Analysis artifacts	log promptów/ modeli AI	prompt + wersja modelu	ukryty udział AI (np. ABM)
L5	Submission	replication package (AEA)	pakiet danych/kodu	brak downstream replikacji
L7	(przekrojowa)	kryterium akceptacji	jakość planu, nie wynik	publication bias

Źródło: opracowanie własne.

7.6 Rola AI w badaniach ekonomicznych

Ekonomia coraz częściej sięga po agentów LLM - do przeglądu literatury, generowania kodu ekonometrycznego, a w modelowaniu agentowym wprost jako elementu samej metody. Gao i współautorzy (2024) pokazują LLM jako rdzeń symulacji agentowych rynków i społeczeństw - zastosowanie, w którym prompt i model są specyfikacją eksperymentu [10.1057/s41599-024-03611-3]. To czyni warstwę L6, czyli proveniencję AI, nie abstrakcyjnym postulatem, lecz konkretnym wymogiem: jeśli wynik zależy od promptu i wersji modelu, oba te elementy muszą być zalogowane i wersjonowane na równi z kodem. Standardowe polityki AEA jeszcze tego nie wymagają - jest to luka, którą SDD wypełnia z wyprzedzeniem. Kotwicę ekonomiczną dokłada tu Charness, Jabarian i List (2023): LLM jako asystenci na etapie projektowania, implementacji i analizy eksperymentów ekonomicznych, z zamrożeniem interakcji badacz-AI - logu promptów jako załącznika - jako artefaktu audytowalnego [10.3386/w31679].

7.7 Ograniczenia adaptacji

Uczciwość wobec własnych ustaleń wymaga trzech zastrzeżeń. Rozdział proponuje upstream workflow, ale nie dowodzi empirycznie, że redukuje on bias - to zadanie dla osobnego badania przeprowadzonego na realnych danych finansowych. Część ryzyk, zwłaszcza tych związanych z danymi point-in-time i wersjami real-time, wymaga infrastruktury danych, która nie wszędzie istnieje, a dla niektórych szeregów historycznych snapshot point-in-time jest po prostu niedostępny. Wreszcie 19 zakodowanych prac z ekonomicznym venue to dobór celowy z 71 pozycji o ekonomicznym venue w korpusie - próba prac otwartego dostępu, przy 33 pozycjach za paywallem poza zasięgiem tej fazy, co jest ograniczeniem kanału pozyskiwania pełnych tekstów spójnym z substytucją baz opisaną w §3.7 - a nie przegląd reprezentatywny praktyki ekonomicznej. Kotwice ilustrują transfer ramy warstwa po warstwie, nie mierzą częstości praktyk w dyscyplinie, a sama próba jest celowa i proporcjonalna do warstw, nie losowa. Metryka 71 prac z

ekonomicznym venue mierzy pokrycie tematyczne korpusu, a nie głębię kodowania: pełny tekst zakodowano dla 41 prac, z czego 19 pochodzi z ekonomicznego venue.

Ten transfer ramy do konkretnej dyscypliny stawia pytanie ogólniejsze: jak SDD wypada na tle własnych ograniczeń metodologicznych i jakie granice stosowalności ujawnia poza samą ekonomią - to przedmiot kolejnego rozdziału.

8. Ryzyka i pytania otwarte

Rama zbudowana w rozdziałach 6-7 - siedem warstw SDD, workflow łączący je w spójny proces badawczy i jego przełożenie na ekonomię - jest propozycją, nie zwalidowanym standardem. Uczciwość wobec czytelnika wymaga wyłożenia jej napięć wewnętrznych, zanim zrobi to recenzent. Rozdział ten odpowiada na część czwartego pytania badawczego od strony granic: nie „co rama dokłada”, lecz „gdzie rama może zawieść albo szkodzić”. Każde z pięciu ryzyk omawiamy wraz z możliwym kierunkiem rozwiązania - nie po to, by je zamknąć, lecz by pokazać, że są to problemy projektowe do dalszego przepracowania, a nie zarzuty unieważniające całość propozycji.

Czy zbyt sztywny workflow hamuje odkrycie?

To najpoważniejszy zarzut merytoryczny, jaki można postawić ramie. Zamrożenie planu analizy przed danymi na poziomie L1 chroni przed HARKingiem, ale realne odkrycie bywa nieplanowane - najciekawszy wynik to często ten, którego nikt nie przewidział. Workflow, który karałby odejście od specyfikacji, groziłby zabiciem eksploracji zamiast jej dyscyplinowania.

Rama odpowiada na to napięcie nie przez zniesienie bramy, lecz przez jawną separację trybów. SDD dziedziczy tu z podejścia multiverse analysis na poziomie L2 oraz z pracy Olkena (2015) rozdział części confirmacyjnej, czyli prespecyfikowanej, od części eksploracyjnej. Eksploracja pozostaje dozwolona i pożądana - pod warunkiem, że jest oznaczona jako eksploracja, a jej wyniki nie są prezentowane w języku potwierdzenia. Sztywność dotyczy więc nie tego, co wolno badać, lecz tego, jak silnie wolno twierdzić. Otwarte pozostaje natomiast, jak zaprojektować bramę, która dopuszczałaby re-specyfikację - nowy, jawnie datowany plan - nie otwierając zarazem furtki do cichego p-hackingu; to problem projektowania protokołu, którego niniejszy artykuł nie rozstrzyga.

Jak klasyfikować wyniki z eksploracji?

To bezpośrednia konsekwencja poprzedniego napięcia. Skoro eksploracja jest dozwolona, potrzebna staje się dyscyplina języka wniosków, będąca piątym punktem oryginalności ramy: wynik eksploracyjny musi nieść etykietę statusu dowodu. Problem jest realny, ponieważ granica bywa nieostra - analiza zaczęta jako confirmacyjna może wygenerować pytanie uboczne, a autor ma naturalną pokusę, by awansować je do rangi ustalenia.

Rozwiązaniem wydaje się uczynienie statusu wyniku - confirmacja, eksploracja, hipoteza do dalszego testu - polem metadanych artefaktu wynikowego, zamrażanym razem z nim, a nie dopisywanym dopiero przy redakcji manuskryptu. Przenosi to klasyfikację z retoryki tekstu do proveniencji danych, zgodnie z zasadą, że tekst jest produktem artefaktów, czyli czwartym punktem oryginalności ramy. Otwarte pozostaje jednak, kto i według jakiego kryterium rozstrzyga przypadki graniczne - to pozostaje bramą człowieka, nie regułą automatyczną.

Kiedy weryfikator AI jest wystarczająco niezależny?

Warstwa L6 postuluje niezależną weryfikację, na przykład przez drugiego agenta sprawdzającego kod lub wynik. Problem w tym, że dwa modele z tej samej rodziny dzielą te same błędy systematyczne - „niezależny” weryfikator oparty na tym samym LLM co generator może w istocie potwierdzać własne halucynacje. AI Scientist (Lu i in. 2024) jawnie ostrzega, że system potrafi halucynować całe wyniki; weryfikator z tego samego źródła nie jest wtedy zabezpieczeniem, lecz echem.

Kierunkiem rozwiązania jest traktowanie niezależności weryfikatora jako wymiaru do zadeklarowania, nie do założenia. Proweniencja AI, trzeci punkt oryginalności ramy, powinna logować nie tylko to, że weryfikacja zaszła, lecz czym była: innym modelem, inną rodziną modeli, człowiekiem, czy narzędziem deterministycznym, takim jak testy jednostkowe kodu. Realna niezależność rośnie stopniowo - od „tego samego modelu”, przez „inną rodzinę”, aż po „weryfikację nie-AI” - a artykuł nie rozstrzyga, gdzie na tej skali leży próg wystarczalności; to pytanie empiryczne, zależne od dziedziny i stawki wyniku.

Jak ujawniać udział AI w manuskrypcie?

Standardy czasopism dotyczące deklaracji użycia AI są dopiero w powijakach i pozostają niespójne. Rama wymaga proveniencji AI - promptów, modeli, wersji - lecz nie istnieje jeszcze uzgodniony format jej ujawniania; polityki AEA data/code na poziomie L5 tego nie obejmują, na co wskazano już jako na lukę w podrozdziale 7.5.

Rozwiązaniem wydaje się potraktowanie ujawniania AI jako rozszerzenia replication package, a nie osobnej sekcji prozą. Skoro prompty i wersje modeli są już zamrożone jako artefakty na poziomie L6, ich ujawnienie sprowadza się do dołączenia logu do pakietu zgłoszeniowego - tej samej infrastruktury, która obsługuje kod i dane. Otwarte pozostaje jednak, jak pogodzić to z niedeterminizmem modeli, gdzie ten sam prompt daje różne wyniki, oraz ze zmianami wersji API po stronie dostawcy: proveniencja może utrwalić prompt, ale nie zawsze pozwoli odtworzyć dokładny wynik.

Jak mierzyć skuteczność samej metodologii?

To pytanie meta i zarazem najtwardsze ograniczenie całej propozycji. Artykuł twierdzi, że SDD podnosi wiarygodność badań, ale nie dostarcza na to dowodu - rama jest sprawdzona na jednej instancji, powstawaniu tego właśnie artykułu, nie zwalidowana na próbie. Nie jest to fałszywa skromność: bez pomiaru „skuteczność” pozostaje twierdzeniem projektowym, nie empirycznym.

Kierunek rozwiązania, rozwinięty w rozdziale 9, prowadzi przez empiryczną walidację na kilku niezależnych instancjach badawczych - porównanie badań prowadzonych z ramą i bez niej pod kątem odtwarzalności, wykrywalności odejść od planu oraz wskaźnika wyników fałszywie dodatnich. Wymaga to jednak metryki, której artykuł jeszcze nie ma, i próby, której jeszcze nie zebrano. Uczciwa odpowiedź brzmi zatem: skuteczność SDD jest hipotezą do przetestowania, nie ustaleniem tego przeglądu.

Ograniczenia samego przeglądu

Poza napięciami samej ramy uczciwość wymaga nazwania granic tej pracy jako przeglądu. Cztery z nich wydają się kluczowe:

1. **Baza wyszukiwania.** Korpus zbudowano na OpenAlex, arXiv i Crossref, nie na Scopus, Web of Science czy EconLit, które pozostają za paywallem. Zmienia to pokrycie: OpenAlex ma szeroki zasięg, ale inną strukturę indeksowania niż WoS, więc część prac ekonomicznych z zamkniętych źródeł mogła nie wejść do analizy. Metryka 71 prac z ekonomicznym venue mierzy zatem pokrycie w tym konkretnym korpusie, nie w całej literaturze.
2. **Głębina kodowania.** Pełnotekstowo zakodowano 41 prac (28 w mapie przekrojowej L1-L6 z fazy 02, wytypowanych z 56 i 582 przesianych, plus 13 w podpróbce ekonomicznej z rozdziału 7) - pozostałe wymagały ręcznego dostępu do treści z paywalla. Twierdzenia o warstwach opierają się więc na próbie celowej, nie wyczerpującej.
3. **Status metodyki.** SDD ma status *provisional* - jest sprawdzone na jednej instancji, nie zwalidowane jako standard, co szerzej omówiono w podrozdziale poświęconym pomiarowi skuteczności metodologii.
4. **Udział AI w powstaniu tekstu.** Artykuł powstał z użyciem asystenta AI (Claude Science): przeszukiwanie korpusu, kodowanie interpretacyjne z weryfikacją cytatów, draftowanie prozy. Zgodnie z własną ramą, na poziomie L6, udział ten jest jawny, a nie ukryty - proces jest udokumentowany w dzienniku `_LOG_procesu/` zgodnie z metodyką FSAIM [10.2139/ssrn.6853581], w ramach której ten artykuł powstał. Kodowanie interpretacyjne, choć weryfikowane programowo wobec tekstu źródłowego, niesie ryzyko błędu, które człowiek-autor nadzoruje przez bramy adjudykacyjne.

Te cztery ograniczenia nie unieważniają wkładu tej pracy - mapowania, syntezy, przeniesienia ramy do ekonomii - ale wyznaczają jego zasięg: jest to propozycja ramy oparta na przeglądzie o określonym pokryciu, nie ostateczny audyt pola. Właśnie stąd wynika kierunek rozdziału następnego, w którym te otwarte pytania - walidacja empiryczna na przedzie - stają się programem badawczym, a nie jedynie listą zastrzeżeń.

9. Wnioski

9.1 SDD jako kompilator dobrych praktyk

Rozdział poprzedni domknął dyskusję ograniczeń metody sformułowanych w §8.5; tutaj pozostaje spiąć wątki w jedną odpowiedź na pytanie postawione na wstępie artykułu. Przegląd wyszedł od cichej podatności badań empirycznych: setki drobnych decyzji analitycznych po drodze do wyniku, z których pokazuje się tylko tę kombinację, która „wyszła”. Nauka wypracowała przeciw temu osobne zabezpieczenia - prerejestrację, analizę wielu wariantów, reprodukowalność kodu i danych, standardy proveniencji, polityki data/code - ale każde z nich chroni jeden fragment procesu, a rozproszone są po dyscyplinach, które rzadko czytają się nawzajem.

Mapowanie tych podejść na sześć warstw (rozdz. 4, RQ1) i ich synteza (rozdz. 5, RQ2) pokazały, że dzielą one jeden mechanizm: zamrożenie decyzji jako audytowalnego obiektu w określonym momencie procesu. To jest oś, na której stoi teza artykułu. SDD nie jest kolejnym, osobnym zabezpieczeniem ani - wbrew pierwszemu wrażeniu - narzędziem do pisania czy kodowania z AI; jest architekturą kontroli epistemicznej, sposobem pracy, który składa rozproszone podejścia w jeden wykonywalny workflow z bramami zatwierdzania przez człowieka (rozdz. 6, RQ3).

To, co rama dokłada ponad zsyntetyzowane warstwy (RQ3-RQ4), to cztery elementy, których żadne z podejść nie miało razem: rozliczalność udziału AI, rozumianą jako prompty, modele i agenci traktowani jako obiekty proveniencji; budowę manuskryptu jako deterministycznego produktu artefaktów; jawne bramy człowieka między etapami; oraz dyscyplinę języka wniosków związaną ze statusem dowodu. Przeniesienie ramy do ekonomii i finansów (rozdz. 7, RQ5) pokazało z kolei, że zyskuje ona najwięcej tam, gdzie dane są wtórne - bo ciężar kontroli przesuwa się wówczas z pytania „czy zebrano dane uczciwie” na pytanie „czy przetworzono je uczciwie”, a to domena, w której zamrażanie decyzji o danych daje konkretny, mierzalny zysk.

Stąd metafora domykająca całość: SDD jest kompilatorem dobrych praktyk. Nie wynajduje kontroli wiarygodności od zera - kompiluje istniejące, sprawdzone podejścia w jeden przebieg, dokładając brakujący we wszystkich element, jakim jest rozliczalność AI. Najmocniejsze sformułowanie do obrony pozostaje tym z rozdziału pierwszego: *SDD for empirical research is a workflow-level synthesis of open science, reproducible research, provenance standards, and AI accountability - not merely an AI-assisted writing or coding method.*

9.2 Odpowiedź na główny zarzut

Najpoważniejszy zarzut, jaki można postawić tej propozycji, brzmi: to tylko preregregacja plus reprodukowalność pod nową nazwą. Przegląd odpowiada na niego nie deklaracją, lecz treścią rozdziałów 5-8. Preregistracja (L1) nie obejmuje reprodukowalności obliczeń, reprodukowalność (L3) nie obejmuje prespecyfikacji, a żadna z tych dwóch warstw z osobna nie obejmuje rozliczalności AI, budowy tekstu z artefaktów ani dyscypliny formułowania twierdzeń. Wartość SDD leży dokładnie w spoinie między nimi - w tym, że wymusza wszystkie warstwy naraz i dokłada te, których w żadnym dotychczasowym zestawie nie było. Kompilator nie jest bowiem „tylko sumą” bibliotek, które łączy; jest tym, co czyni je wykonywalnymi razem.

9.3 Kierunek: empiryczna walidacja

Artykuł jest przeglądem i propozycją, nie dowodem skuteczności - ograniczenie to nazwano wprost w §8.5. Naturalnym następnym krokiem pozostaje empiryczna walidacja SDD na kilku niezależnych instancjach badawczych: porównanie badań prowadzonych z ramą i bez niej pod kątem odtwarzalności wyników, wykrywalności odejść od zamrożonego planu oraz wskaźnika wyników fałszywie dodatnich. Wymaga to metryki skuteczności metodyki, której ten artykuł jeszcze nie proponuje, oraz próby badań, której jeszcze nie zebrano. Do czasu takiej walidacji status ramy pozostaje *provisional* - sprawdzony na jednej instancji, jaką było powstawanie tego tekstu pod metodyką FSAIM [10.2139/ssrn.6853581], ale nie ustalony jako standard.

Aby rama była falsyfikowalna, formułujemy trzy przewidywania, które przyszłe badanie może potwierdzić lub obalić. Po pierwsze, w wymiarze odtwarzalności badania prowadzone z pełnym wariantem SDD powinny osiągać wyższy odsetek niezależnie odtworzonych wyników niż dopasowane badania bez ramy - jeśli różnica okaże się zerowa lub ujemna, wkład ramy w odtwarzalność jest obalony. Po drugie, w wymiarze wykrywalności odejść od planu odejścia od prespecyfikacji w badaniach z zamrożonym planem analizy (L1+L2) powinny być wykrywalne z samych artefaktów, bez dostępu do wiedzy autora - jeśli audytor nie odróżni analizy prespecyfikowanej od eksploracyjnej lepiej niż losowo, warstwa zamrożenia planu nie daje obiecywanej audytowalności. Po trzecie, w wymiarze rozliczalności AI obecność obowiązkowego logu proveniencji (L6) powinna zwiększać wykrywalność błędów pochodzenia AI, takich jak zmyślane cytowania czy dryf modelu - jeśli wskaźnik wykrycia nie rośnie, log proveniencji jest kosztem bez korzyści audytowej. Każde z tych przewidywań wskazuje mierzalną wielkość i

warunek, który falsyfikuje odpowiedni element ramy; ich operacjonalizacja jest przedmiotem zapowiadzanego osobnego badania walidacyjnego, nie tego przeglądu.

To jest uczciwe domknięcie: przegląd zmapował pole, zsyntetyzował je w ramę i pokazał, gdzie ta rama sięga dalej niż jej składniki. Czy sięga skutecznie - to pytanie, na które odpowie dopiero pomiar, nie argument. Artykuł stawia ramę i wskazuje, jak ją obalić lub potwierdzić; reszta należy do danych.

Bibliografia

1. Banerjee, Abhijit, Duflo, Esther, Finkelstein, Amy, Katz, Lawrence F., Olken, Benjamin A., Sautmann, Anja (2020). In Praise of Moderation: Suggestions for the Scope and Use of Pre-Analysis Plans for RCTs in Economics. *NBER Working Paper Series*. <https://doi.org/10.3386/w26993>
2. Bechhofer, Sean, Roure, David De, Gamble, Matthew, Goble, Carole, Buchan, Iain (2010). Research Objects: Towards Exchange and Reuse of Digital Knowledge. *Nature Precedings*. <https://doi.org/10.1038/npre.2010.4626.1>
3. Beck, Susanne, Bergenholtz, Carsten, Bogers, Marcel, Brasseur, Tiare-Maria, Conradsen, Marie Louise, Marco, Diletta Di, Distel, Andreas, Dobusch, Leonhard, Dörler, Daniel, Effert, Agnes, Fecher, Benedikt, Filiou, Despoina, Frederiksen, Lars, Gillier, Thomas, Grimpe, Christoph, Gruber, Marc, Haeussler, Carolin, Heigl, Florian, Hoisl, Karin, Hyslop, Katie, Kokshagina, Olga, LaFlamme, Marcel, Lawson, Cornelia, Lifshitz-Assaf, Hila, Lukas, W., Nordberg, Markus, Norn, Maria-Theresa, Poetz, Marion, Ponti, Marisa, Pruschak, Gernot, Priego, Laia Pujol, Radziwon, Agnieszka, Rafner, Janet, Romanova, Gergana Petrova, Ruser, Alexander, Sauermann, Henry, Shah, Sonali, Sherson, Jacob, Suess-Reyes, Julia, Tucci, Christopher L., Tuertscher, Philipp, Vedel, Jane Bjørn, Velden, Theresa, Verganti, Roberto, Wareham, Jonathan, Wiggins, Andrea, Xu, Sunny Mosangzi (2020). The Open Innovation in Science research field: a collaborative conceptualisation approach. *Industry and Innovation*. <https://doi.org/10.1080/13662716.2020.1792274>
4. Benjamini, Yoav, Yekutieli, Daniel (2001). The control of the false discovery rate in multiple testing under dependency. *The Annals of Statistics*. <https://doi.org/10.1214/aos/1013699998>
5. Boiko, Daniil A., MacKnight, Robert, Kline, Ben, Gomes, Gabriel dos Passos (2023). Autonomous chemical research with large language models. *Nature*. <https://doi.org/10.1038/s41586-023-06792-0>
6. Borusyak, Kirill, Jaravel, Xavier, Spiess, Jann (2024). Revisiting Event-Study Designs: Robust and Efficient Estimation. *Review of Economic Studies*. <https://doi.org/10.1093/restud/rdae007>
7. Bran, Andres M., Cox, Sam, Schilter, Oliver, Baldassari, Carlo, White, Andrew Dickson, Schwaller, Philippe (2024). Augmenting large language models with chemistry tools. *Nature Machine Intelligence*. <https://doi.org/10.1038/s42256-024-00832-8>
8. Carroll, Stephanie Russo, Garba, Ibrahim, Rodríguez, Óscar Luis Figueroa, Holbrook, Jarita, Lovett, Raymond, Materechera, S. A., Parsons, M. A., Raseroka, Kay, Rodriguez-Lonebear, Desi, Rowe, Robyn, Sara, Rodrigo, Walker, Jennifer, Anderson, Jane, Hudson, Māui (2020). The CARE Principles for Indigenous Data Governance. *Data Science Journal*. <https://doi.org/10.5334/dsj-2020-043>
9. Chang, Andrew C., Li, Phillip (2015). Is Economics Research Replicable? Sixty Published Papers from Thirteen Journals Say "Usually Not". *Finance and Economics Discussion Series*. <https://doi.org/10.17016/feds.2015.083>
10. Charness, Gary, Jabarian, Brian, List, John A. (2023). Generation Next: Experimentation with AI. *NBER Working Paper Series*. <https://doi.org/10.3386/w31679>

11. Chen, Chuke, Luo, Biao, Li, Nan, Wang, Boxiang, Yang, Hang, Guo, Jing, Xu, Ming (2025). Spec-Driven AI for Science: The ARIA Framework for Automated and Reproducible Data Analysis. *arXiv*. <https://arxiv.org/abs/2510.11143>
12. Christensen, Garret, Miguel, Edward (2018). Transparency, Reproducibility, and the Credibility of Economics Research. *Journal of Economic Literature*. <https://doi.org/10.1257/jel.20171350>
13. Christensen, Garret, Dafoe, Allan, Miguel, Edward, Moore, Don A., Rose, Andrew K. (2019). A study of the impact of data sharing on article citations using journal policies as a natural experiment. *PLoS ONE*. <https://doi.org/10.1371/journal.pone.0225883>
14. Duvendack, Maren, Palmer-Jones, Richard, Reed, W. Robert (2017). What Is Meant by “Replication” and Why Does It Encounter Resistance in Economics?. *American Economic Review*. <https://doi.org/10.1257/aer.p20171031>
15. Forkel, Robert, List, Johann-Mattis, Greenhill, Simon J., Rzymiski, Christoph, Bank, Sebastian, Cysouw, Michael, Hammarström, Harald, Haspelmath, Martín, Kaiping, Gereon A., Gray, Russell D. (2018). Cross-Linguistic Data Formats, advancing data sharing and re-use in comparative linguistics. *Scientific Data*. <https://doi.org/10.1038/sdata.2018.205>
16. Gao, Chen, Lan, Xiaochong, Li, Nian, Yuan, Yuan, Ding, Jingtao, Zhou, Zhilun, Xu, Fengli, Li, Yong (2024). Large language models empowered agent-based modeling and simulation: a survey and perspectives. *Humanities and Social Sciences Communications*. <https://doi.org/10.1057/s41599-024-03611-3>
17. German Journal of Agricultural Economics (2023). The p-Value Debate and Statistical (Mal)practice – Implications for the Agricultural and Food Economics Community. *German Journal of Agricultural Economics*. <https://doi.org/10.30430/gjae.2023.0231>
18. Giofrè, David, Cumming, Geoff, Fresc, Luca, Boedker, Ingrid, Tressoldi, Patrizio (2017). The influence of journal submission guidelines on authors’ reporting of statistics and use of open research practices. *PLoS ONE*. <https://doi.org/10.1371/journal.pone.0175583>
19. Hagger, Martin S., Chatzisarantis, Nikos L. D., Alberts, H., Anggono, Calvin Octavianus, Batailler, Cédric, Birt, Angela R., Brand, Ralf, Brand, Muriele, Brewer, Gayle, Bruyneel, S., Calvillo, Dustin P., Campbell, Wenonah, Cannon, Peter Robert, Carlucci, M., Carruth, Nicholas P., Cheung, Tracy, Crowell, Adrienne, Ridder, Denise de, Dewitte, Siegfried, Elson, Malte, Evans, Jacqueline R., Fay, Anne L., Fennis, Bob M., Finley, Anna J, Francis, Zoë, Heise, Elke, Hoemann, Harry W., Inzlicht, Michael, Koole, Sander L., Koppel, Lina, Kroese, Floor M., Lange, Florian, Lau, Karen, Lynch, Patricia A., Martijn, Carolien, Merckelbach, Harald, Mills, Neil P., Michirev, Alexej, Miyake, Akira, Mosser, A., Muise, Megan D., Müller, Dominique, Muzi, M Gallinella, Nalis, Dario, Nurwanti, Ratri, Otgaar, Henry, Philipp, Michael, Primoceri, Pierpaolo, Rentzsch, Katrin, Ringos, Lara Jade, Schlinkert, Caroline, Schmeichel, Brandon J., Schoch, Sarah F., Schrama, Maarten, Schütz, Astrid, Stamos, Angelos, Tinghög, Gustav, Ullrich, Johannes, vanDellen, Michelle R., Wimbarti, Supra, Wolff, Wanja, Yusainy, Cleoputri, Zerhouni, Oulmann, Zwienenberg, M. (2016). A Multilab Preregistered Replication of the Ego-Depletion Effect. *Perspectives on Psychological Science*. <https://doi.org/10.1177/1745691616652873>
20. Ioannidis, John P. A. (2005). Why Most Published Research Findings Are False. *PLoS Medicine*. <https://doi.org/10.1371/journal.pmed.0020124>
21. Kerr, Norbert L. (1998). HARKing: Hypothesizing After the Results are Known. *Personality and Social Psychology Review*. https://doi.org/10.1207/s15327957pspr0203_4
22. Kurtzer, Gregory M., Sochat, Vanessa, Bauer, Michael W. (2017). Singularity: Scientific containers for mobility of compute. *PLoS ONE*. <https://doi.org/10.1371/journal.pone.0177459>

23. List, John A., Shaikh, Azeem M., Xu, Yang (2016). Multiple Hypothesis Testing in Experimental Economics. *National Bureau of Economic Research*. <https://doi.org/10.3386/w21875>
24. Lu, Chris, Lu, Cong, Lange, Robert Tjarko, Foerster, Jakob, Clune, Jeff, Ha, David (2024). The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery. *arXiv*. <https://arxiv.org/abs/2408.06292>
25. Menkveld, Albert J., Dreber, Anna, Holzmeister, Felix, Huber, Juergen, Johannesson, Magnus, Kirchler, Michael, others (2024). Nonstandard Errors. *Journal of Finance*. <https://doi.org/10.1111/jofi.13337>
26. Miguel, Edward (2021). Evidence on Research Transparency in Economics. *Journal of Economic Perspectives*. <https://doi.org/10.1257/jep.35.3.193>
27. Moher, David, Bouter, L.M., Kleinert, Sabine, Glasziou, Paul, Sham, MH, Barbour, Virginia, Coriat, Anne-Marie, Foeger, Nicole, Dirnagl, Ulrich (2020). The Hong Kong Principles for assessing researchers: Fostering research integrity. *PLoS Biology*. <https://doi.org/10.1371/journal.pbio.3000737>
28. Munafò, Marcus R., Nosek, Brian A., Bishop, Dorothy, Button, Katherine S., Chambers, Chris, Sert, Nathalie Percie du, Simonsohn, Uri, Wagenmakers, Eric-Jan, Ware, Jennifer J., Ioannidis, John P. A. (2017). A manifesto for reproducible science. *Nature Human Behaviour*. <https://doi.org/10.1038/s41562-016-0021>
29. Ofosu, George Kwaku, Posner, Daniel (2020). Do Pre-analysis Plans Hamper Publication?. *AEA Papers and Proceedings*. <https://doi.org/10.1257/pandp.20201079>
30. Olken, Benjamin (2015). Promises and Perils of Pre-Analysis Plans. *The Journal of Economic Perspectives*. <https://doi.org/10.1257/jep.29.3.61>
31. Open Science Collaboration (2015). Estimating the reproducibility of psychological science. *Science*. <https://doi.org/10.1126/science.aac4716>
32. Ramos, Mayk Caldas, Collison, Christopher J., White, Andrew Dickson (2024). A review of large language models and autonomous agents in chemistry. *Chemical Science*. <https://doi.org/10.1039/d4sc03921a>
33. Romano, Joseph P., Wolf, Michael (2005). Stepwise Multiple Testing as Formalized Data Snooping. *Econometrica*. <https://doi.org/10.1111/j.1468-0262.2005.00615.x>
34. Schmidgall, Samuel, Su, Yusheng, Wang, Ze, Sun, Ximeng, Wu, Jialian, Yu, Xiaodong, Liu, Jiang, Moor, Michael, Liu, Zicheng, Barsoum, Emad (2025). Agent Laboratory: Using LLM Agents as Research Assistants. *arXiv*. <https://arxiv.org/abs/2501.04227>
35. Simmons, Joseph P., Nelson, Leif D., Simonsohn, Uri (2011). False-Positive Psychology. *Psychological Science*. <https://doi.org/10.1177/0956797611417632>
36. Simonsohn, Uri, Simmons, Joseph P., Nelson, Leif D. (2020). Specification curve analysis. *Nature Human Behaviour*. <https://doi.org/10.1038/s41562-020-0912-z>
37. Soiland-Reyes, Stian, Sefton, Peter, Crosas, Mercè, Castro, Leyla Jael, Coppens, Frederik, Fernández, José M., Garijo, Daniel, Grüning, Björn, Rosa, M., Leo, Simone, Carragáin, Eoghan Ó, Portier, Marc, Trisovic, A., Community, RO-Crate, Groth, Paul, Goble, Carole (2022). Packaging research artefacts with RO-Crate. *Data Science*. <https://doi.org/10.3233/ds-210053>
38. Steegen, Sara, Tuerlinckx, Francis, Gelman, Andrew, Vanpaemel, Wolf (2016). Increasing Transparency Through a Multiverse Analysis. *Perspectives on Psychological Science*. <https://doi.org/10.1177/1745691616658637>
39. Vilhuber, Lars (2020). Reproducibility and Replicability in Economics. *Harvard Data Science Review*. <https://doi.org/10.1162/99608f92.4f6b9e67>

40. Wallis, Jillian C., Rolando, Elizabeth, Borgman, Christine L. (2013). If We Share Data, Will Anyone Use Them? Data Sharing and Reuse in the Long Tail of Science and Technology. *PLoS ONE*. <https://doi.org/10.1371/journal.pone.0067332>
41. White, Halbert (2000). A Reality Check for Data Snooping. *Econometrica*. <https://doi.org/10.1111/1468-0262.00152>
42. Wilkinson, Mark D., Dumontier, Michel, Aalbersberg, IJsbrand Jan, Appleton, Gabrielle, Axton, Myles, Baak, Arie, Blomberg, Niklas, Boiten, Jan-Willem, Santos, Luiz Olavo Bonino da Silva, Bourne, Philip E., Bouwman, Jildau, Brookes, Anthony J., Clark, Tim W., Crosas, Mercè, Dillo, Ingrid, Dumon, Olivier, Edmunds, Scott, Evelo, Chris T., Finkers, Richard, González-Beltrán, Alejandra, Gray, Alasdair J. G., Groth, Paul, Goble, Carole, Grethe, Jeffrey S., Heringa, Jaap, Hoen, Peter A.C. 't, Hooft, Rob, Kuhn, Tobias, Kok, Ruben, Kok, Joost N., Lusher, Scott J., Martone, Maryann E., Mons, Albert, Packer, Abel L., Persson, Bengt, Rocca-Serra, Philippe, Roos, Marco, Schaik, René van, Sansone, Susanna-Assunta, Schultes, Erik, Sengstag, Thierry, Slater, Ted, Strawn, George, Swertz, Morris A., Thompson, Mark, Lei, Johan van der, Mulligen, Erik M. van, Velterop, Jan, Waagmeester, Andra, Wittenburg, Peter, Wolstencroft, Katherine, Zhao, Jun, Mons, Barend (2016). The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*. <https://doi.org/10.1038/sdata.2016.18>
43. Wilkinson, Sean R., Alokala, Meznah, Belhajjame, Khalid, Crusoe, Michael R., Kinoshita, Bruno P., Gadelha, Luiz, Garijo, Daniel, Gustafsson, Ove, Juty, Nick, Kanwal, Sehrish, Khan, Farah Zaib, Köster, Johannes, Peters, Karsten, Pouchard, Line, Rannow, Randy K., Soiland-Reyes, Stian, Soranzo, Nicola, Sufi, Shoaib, Sun, Ziheng, Vilne, Baiba, Wouters, Merridee A., Yuen, Denis, Goble, Carole (2025). Applying the FAIR Principles to computational workflows. *Scientific Data*. <https://doi.org/10.1038/s41597-025-04451-9>
44. Wojarnik, Grzegorz (2026). FSAIM: Spec-driven AI as a Governance Layer for Empirical Research – A Position Note. *SSRN*. <https://doi.org/10.2139/ssrn.6853581>

Załączniki (Appendix)

Ten przegląd stosuje własną tezę do siebie: aparatura badawcza (zapytania, kryteria, schemat kodowania, ścieżka przesiewu) jest udostępniona jako zbiór audytowalnych artefaktów, nie opisana ogólnikowo. Poniższe załączniki pozwalają odtworzyć korpus i kodowanie niezależnie.

Załącznik A - Strategia wyszukiwania i log przeszukań

Pełny, wykonywalny log zapytań (bazy, ciągi wyszukiwania, daty, liczby trafień, decyzje o włączeniu warstw) znajduje się w `./01_search_korpus/SEARCH_LOG.md`. Kluczowe fakty:

- **Bazy:** OpenAlex (główna), arXiv, Crossref - otwarte API zastępujące paywallowany Scopus/WoS/EconLit (uzasadnienie: `./FEASIBILITY_claude_science.md`).
- **Strumienie tematyczne:** sześć warstw (L1 prerejestracja, L2 multiverse, L3 reprodukowalność, L4 FAIR/prowienicja, L5 polityki data/code, L6 AI-for-science) + kotwice cytowań.
- **Filtr czasowy:** zapytania tematyczne od 1998 (bez górnej granicy); prace wcześniejsze wchodzą wyłącznie przez kotwice/rozszerzenie cytowań (korpus 1955-2026).
- **Metoda przesiewu:** deterministyczny słownik słów kluczowych na tytułach i abstraktach (odtwarzalny, zapisywany - nie klasyfikacja LLM).

Załącznik B - Diagram przepływu PRISMA-ScR

Ścieżka od rekordów surowych przez deduplikację, przesiew tytuł/abstrakt, do korpusu włączonego (582 prace) - ../01_search_korpus/fig_corpus_v3_prisma.png (PL) / ..._en.png (EN). Rozkład warstw w korpusie włączonym: L3 reprodukowalność 246, L1 prerejestracja 102, L2 multiverse 73, meta 67, L6 AI 46, L4 FAIR 33, L5 polityki 15.

Załącznik C - Schemat kodowania i zakodowany zbiór

Schemat 16 pól interpretacyjnych (problem wiarygodności, mechanizm kontroli, moment, jednostka zamrożenia, wymagane artefakty, rola człowieka/AI, proweniencja danych/kodu/AI, podejście do eksploracji/konfirmacji/odchylen, transferowalność do ekonomii, ryzyka, import do SDD) - ../02_przesiew_kodowanie/coding_sheet.csv (56 prac wytypowanych; **28 zakodowanych pełnotekstowo**, reszta wymagała ręcznego dostępu zza paywalla). Kalibracja schematu: ../02_przesiew_kodowanie/KALIBRACJA_kodowania.md. Weryfikacja pól średniej pewności: ../02_przesiew_kodowanie/WERYFIKACJA_srednia_pewnosc.md. Decyzje adjudykacyjne: ../02_przesiew_kodowanie/ADJUDYKACJA_decyzje.md.

Zasada kontroli jakości kodowania: **każdy cytat weryfikowany programowo** - musi dosłownie występować w tekście źródłowym, inaczej odrzucany. Atrybucje autorów pobierane z OpenAlex (nigdy z pamięci).

Załącznik D - Prace niedostępne pełnotekstowo

Lista 27 prac, dla których automatyczne pobranie pełnego tekstu było niemożliwe (głównie non-Elsevier zza paywalla: Wiley/Econometrica, AEA, Nature, APA, Oxford) - ../02_przesiew_kodowanie/DO_POBRANIA_reczne.md. Te prace weszły do korpusu i kodowania na podstawie tytułu/abstraktu/metadanych; ich pełnotekstowe kodowanie wymaga ręcznego dostępu (ograniczenie nazwane w §8.6).

Załącznik E - Checklista PRISMA-ScR

Pełna checklista (standard Tricco i in. 2018, 20+2 pozycji) z lokalizacją każdej pozycji w artykule - plik checklista_PRISMA-ScR.md w tym folderze.

Planowane anchorry w tym rozdziale

- (załączniki wskazują artefakty źródłowe przez ścieżki względne; przy budowie manuskryptu - faza 10 - linki podmieniane na numery załączników/figur)